

Прикладные задачи анализа данных

Анализ вклада внутренних и внешних признаков в качество
прогнозирования спроса в розничной сети

Медведев Максим Юрьевич, Радько Роман Олегович — БПМ255

31 мая 2026 г.

Содержание

1	Введение	2
1.1	Постановка задачи	2
1.2	Исходные данные	2
2	Обзор литературы	4
3	Методы	4
3.1	Общая схема	5
3.2	Организация проекта и воспроизводимость экспериментов	6
3.3	Постановка экспериментов	8
3.3.1	Формирование лаговых признаков и контроль утечки данных	8
3.4	Метрики качества	9
3.5	Гиперпараметры моделей	10
4	Результаты	11
4.1	Сравнение моделей и вариантов признаков	11
4.1.1	Базовые прогнозы	13
4.1.2	Лучшие модели	13
4.2	Анализ важности признаков	18
5	Обсуждение	22
5.1	Анализ результатов экспериментов	23
5.2	Интерпретация основных результатов	23
5.3	Практическая значимость	24
5.4	Ограничения исследования и возможные улучшения	24
6	Заключение	25
7	Список литературы	26

1. Введение

1.1. Постановка задачи

Актуальность исследования обусловлена необходимостью повышения точности прогнозирования спроса в розничной торговле. Ошибки прогноза дневных продаж могут приводить к избыточным запасам, дефициту товаров и снижению эффективности операционного планирования.

Объектом исследования являются ежедневные продажи магазинов сети Rossmann. Предметом исследования выступает вклад внутренних и внешних признаков в качество прогнозирования продаж. При этом признаки продаж, строящиеся на основе прошлых значений целевой переменной из исходного датасета, рассматриваются как часть внутренних признаков.

Целью работы является оценка вклада дополнительных групп признаков в качество прогнозирования дневных продаж магазинов по сравнению с моделями, использующими базовый набор признаков датасета Rossmann Store Sales.

В рамках данной работы спрос отождествляется с фактическими продажами **Sales**, поскольку датасет не содержит данных о нереализованном спросе, то есть покупательский интерес, не завершившийся фактической продажей.

Для достижения поставленной цели решаются следующие задачи:

- подготовка исходных данных и объединение их со справочной информацией о магазинах;
- формирование базового набора признаков и дополнительных групп признаков, включая исторические и внешние признаки;
- построение моделей для различных наборов признаков;
- сравнение качество моделей с использованием метрик;
- определение групп признаков, вносящих наибольший вклад в качество прогнозирования.

Исследовательская гипотеза состоит в том, что добавление внешних признаков может улучшить качество прогнозирования по сравнению с базовой моделью. В рамках этой гипотезы также оценивается, какие группы признаков дают наибольший вклад в снижение ошибки прогноза.

1.2. Исходные данные

В качестве исходных данных используется готовый набор Rossmann Store Sales, содержащий историческую информацию о продажах в 1115 магазинах немецкой сети drogери [1].

Представленные в датасете признаки можно классифицировать по типу данных следующим образом:

- числовые;
- категориальные;
- бинарные;

- временные.

Таблица для обучения (`train.csv`) содержит следующие признаки:

- **Store** — идентификатор магазина;
- **DayOfWeek** — день недели (временной признак);
- **Date** — дата (временной признак);
- **Sales** — дневная выручка (числовой признак), являющаяся целевой переменной задачи прогнозирования;
- **Customers** — число покупателей (числовой признак);
- **Open** — был ли магазин открыт (бинарный признак);
- **Promo** — была ли в этот день акция (бинарный признак);
- **StateHoliday** — тип государственного праздника или его отсутствие (категориальный признак);
- **SchoolHoliday** — школьные каникулы (бинарный признак).

Признак **Customers** не использовался при обучении моделей, поскольку в реальной задаче прогнозирования будущих продаж количество покупателей заранее неизвестно. Использование этого признака могло бы привести к утечке информации, то есть к ситуации, когда модель получает данные, которые в реальной задаче заранее были бы неизвестны.

`test.csv` содержит наблюдения, для которых необходимо спрогнозировать целевую переменную **Sales**. В настоящем исследовании этот файл не использовался, поскольку в нём отсутствуют фактические значения **Sales**, необходимые для расчёта метрик качества. Поэтому оценка моделей проводилась на валидационной выборке, сформированной с помощью временного разделения данных из `train.csv`.

Таблица `store.csv` содержит справочную информацию по магазинам:

- **Store** — идентификатор магазина;
- **StoreType** — тип магазина (категориальный признак);
- **Assortment** — тип ассортимента (категориальный признак);
- **CompetitionDistance** — расстояние до ближайшего конкурента (числовой признак);
- **CompetitionOpenSinceMonth** — месяц, когда ближайший конкурент начал работать (временной признак);
- **CompetitionOpenSinceYear** — год, когда ближайший конкурент начал работать (временной признак);
- **Promo2** — участвует ли магазин в длительной повторяющейся промо-кампании (бинарный признак);
- **Promo2SinceWeek** — неделя, с которой началась **Promo2** (временной признак);
- **Promo2SinceYear** — год начала **Promo2** (временной признак);
- **PromoInterval** — месяцы проведения длительной промо-кампании **Promo2** (категориальный признак).

Также использовалась таблица `store_states.csv`, содержащая соответствие магазинов федеральным землям Германии. Она применялась для объединения данных о магазинах с внешними признаками, зависящими от региона.

2. Обзор литературы

Прогнозирование спроса в розничной торговле является сложной задачей, поскольку объём продаж формируется под влиянием множества факторов, включая календарные периоды, характеристики магазина, промоакции, сезонность и условия внешней среды, например погоду. В обзоре Р. Филдса, Ш. Ма и С. Колассы отмечается, что прогнозирование розничного спроса важно как для долгосрочного управления компанией, так и для ежедневных решений на уровне отдельных магазинов и товаров [2].

В современных исследованиях и соревнованиях по прогнозированию спроса широко применяются методы машинного обучения для табличных данных, включая ансамблевые модели на основе решающих деревьев. Результаты соревнования M5 показывают, что в задачах розничного прогнозирования важную роль играют признаки, основанные на прошлых значениях продаж, а также календарные факторы и информация о промоактивности [3]. Отдельные исследования также подчёркивают значимость конструирования промо-признаков. Так, Ш. Ма, Р. Филдс и Т. Хуанг рассматривают задачу прогнозирования продаж на уровне SKU с учётом большого числа признаков, позволяющих учитывать влияние промоакций не только на отдельный товар, но и на связанные с ним товары [4].

Связь погодных условий с продажами также рассматривается в прикладных исследованиях розничной торговли. Например, Н. Роуз и Л. Долега анализируют связь между погодными условиями и ежедневными продажами крупного ритейлера, используя, в том числе, методы случайного леса [5]. Результаты их работы позволяют предположить, что погодные признаки могут быть полезны для прогнозирования спроса.

Отдельное направление исследований связано с использованием поискового интереса как внешнего индикатора потребительского спроса. Х. Чой и Х. Вэриан показали, что данные Google Trends могут быть полезны для краткосрочного прогнозирования экономической активности, поскольку поисковые запросы отражают текущий интерес пользователей до публикации официальной статистики [6]. В рамках данной работы это служит основанием для включения признака `GoogleTrend` в экспериментальный анализ.

Таким образом, существующие исследования подтверждают целесообразность проверки внешних признаков в задачах прогнозирования спроса. При этом заранее нельзя утверждать, что каждый внешний источник данных улучшит качество модели. Его вклад зависит от временного горизонта прогноза, качества агрегации данных, типа товаров и уже имеющихся внутренних признаков. Для оценки моделей временных рядов также важно учитывать порядок наблюдений. В литературе по прогнозированию для этого применяются разбиения, имитирующие прогнозирование будущих периодов, например схема последовательного смещения точки прогноза (*rolling forecasting origin*) [7]; в данной работе использовалось более простое одно временное разбиение на обучающую и валидационную выборки.

3. Методы

3.1. Общая схема

После анализа структуры исходных данных задача была сформулирована как **задача регрессии**: на основе доступных характеристик наблюдения необходимо предсказать дневной объём продаж **Sales**. Поскольку данные представлены в виде временного ряда, при построении и оценке моделей важно сохранять хронологический порядок наблюдений и не перемешивать обучающую и валидационную выборки случайным образом.

В качестве основного направления решения были выбраны методы машинного обучения для табличных данных, в первую очередь ансамблевые методы на основе решающих деревьев. Такой выбор обусловлен тем, что продажи в розничной торговле могут зависеть от большого числа разнородных признаков, а связь между этими признаками и целевой переменной может быть нелинейной.

Одним из наиболее подходящих методов для такой постановки является градиентный бустинг над решающими деревьями. Метод градиентного бустинга был формализован в работе Дж. Фридмана, где рассматривается как последовательное построение аддитивной модели, минимизирующей функцию потерь [8]. В практической части работы использовалась реализация XGBoost, предложенная Т. Ченом и К. Гестрином [9]. Данный алгоритм хорошо подходит для задач с большим числом наблюдений и неоднородными признаками, что соответствует структуре рассматриваемого набора данных.

Также в качестве альтернативных моделей были рассмотрены линейная регрессия и случайный лес. Линейная регрессия использовалась в качестве базовой интерпретируемой модели, с которой сравнивались более сложные алгоритмы машинного обучения. Метод случайного леса был систематически описан Л. Брейманом [10]. В данной работе он используется как альтернативный ансамблевый метод, поскольку способен учитывать нелинейные зависимости между признаками без последовательного построения деревьев, характерного для бустинга.

Выбор ансамблевых моделей на основе решающих деревьев и лаговых признаков соответствует подходам, широко применяемым в современных задачах прогнозирования розничных продаж. В частности, результаты соревнования M5 показывают значимость моделей градиентного бустинга и признаков, основанных на прошлых значениях продаж [3].

Общий ход исследования был следующим. Сначала исходные данные были очищены и объединены со справочной информацией о магазинах. Затем были сформированы дополнительные признаки: календарные признаки, фиктивные признаки для категориальных признаков, признаки праздников, погодные признаки, признак уровня безработицы, Google Trends, взаимодействия промо-акций и погоды, а также лаговые признаки продаж. Далее все признаки были разделены на несколько смысловых групп, что позволило провести серию экспериментов с различными наборами признаков.

Для оценки качества моделей исходная обучающая выборка была разделена на обучающую и валидационную части по времени. Наблюдения до 2015-06-01 использовались для обучения, а наблюдения начиная с 2015-06-01 — для валидации.

Качество моделей оценивалось с помощью трёх метрик: RMSPE, MAE и R^2 . Основной метрикой сравнения была выбрана RMSPE, поскольку она измеряет относительную ошибку прогноза и учитывает различия в масштабе продаж между магазинами. После сравнения моделей и вариантов признаков для лучших моделей был проведён анализ важности признаков, позволяющий определить, какие признаки были наиболее важны для формирования прогноза.

3.2. Организация проекта и воспроизводимость экспериментов

Для обеспечения воспроизводимости экспериментов проект был организован следующим образом:

```
Sem/  
|-- data/  
|   |-- raw/  
|   |-- external/  
|   '-- cache/  
|-- src/  
|   |-- data/  
|   '-- models/  
|-- outputs/  
|   |-- figures/  
|   |-- models/  
|   '-- reports/  
|-- notebooks/  
|-- requirements.txt  
'-- README.md
```

В папке `data/raw/` хранятся исходные данные Rossmann:

- `train.csv`,
- `test.csv`,
- `store.csv`,
- `store_states.csv`.

В папке `data/external/` хранятся внешние данные:

- `weather_daytime.csv`,
- `googletrend_self.csv`,
- `unemployment_germany.csv`.

Погодные данные были получены из исторического архива Open-Meteo [11] для столиц федеральных земель Германии. Для каждой федеральной земли загружались почасовые значения температуры воздуха, количества осадков и продолжительности солнечного сияния. Далее были оставлены только наблюдения за часы работы магазинов с 9:00 до 20:00, после чего данные агрегировались до дневного уровня. В результате были сформированы четыре погодных признака: `temperature_mean` — средняя температура за рабочие часы, `temperature_max` — максимальная температура за рабочие часы, `precipitation_sum` — сумма осадков за рабочие часы, `sunshine_sum` — суммарная продолжительность солнечного сияния за рабочие часы.

Данные Google Trends [12] были сформированы для запроса `rossmann` по федеральным землям Германии. Индекс Google Trends представляет собой относительный нормированный показатель поискового интереса в диапазоне от 0 до 100, где 100 соответствует максимальному уровню интереса в выбранном периоде и регионе; в использованной выгрузке он имел недельную частоту. В данной версии предобработки недельные значения присоединялись к дневным данным по совпадающим датам и регионам, а отсутствующие значения далее заполнялись нулями вместе с остальными пропусками. Поэтому результаты для группы `google_trends` интерпретировались осторожно.

Показатель безработицы был получен из FRED [13] как месячный показатель Harmonized Unemployment Rate для Германии. Внешние данные объединялись с основным датасетом по дате и региону; для месячного показателя безработицы значение месяца распространялось на все дни соответствующего месяца.

В папке `src/models/` находятся скрипты обучения и оценки моделей:

- `common.py` — содержит общие функции подготовки данных, формирования признаков и расчёта метрик;
- `model_runtime.py` — содержит вспомогательные функции для сохранения моделей, конфигураций и метаданных экспериментов;
- `baselines.py` — рассчитывает наивные и простые базовые прогнозы для сравнения с моделями машинного обучения;
- `feature_variant_search.py` — перебирает варианты признаков и обучает модели на разных наборах;
- `linear_regression.py` — обучает модель линейной регрессии на выбранном наборе признаков и сохраняет результаты;
- `random_forest.py` — обучает модель случайного леса на выбранном наборе признаков и строит график важности признаков;
- `xgboost_shap.py` — обучает модель XGBoost на выбранном наборе признаков и выполняет SHAP-анализ важности признаков.

В папке `outputs/models/` сохраняются обученные модели и метаданные:

- `linear_regression.pkl`,
- `random_forest.pkl`,
- `xgboost_shap_holidays_lags.json`,
- `feature_columns.json`,
- `preprocessing_config.json`.

В папке `outputs/reports/` сохраняются результаты экспериментов:

- `baseline_metrics.csv`,
- `baseline_metrics.json`,
- `feature_variant_metrics.csv`,
- `feature_variant_metrics.json`,
- `feature_importance_xgboost.csv`,
- `experiments_summary.md`.

В папке `src/data/` находятся скрипты подготовки внешних данных:

- `weather.py`,
- `google_trends_parsing.py`,
- `unemployment.py`.

Актуальная версия проекта размещена в открытом репозитории GitHub: <https://github.com/alwaysnervous/rossman>.

Репозиторий содержит исходный код предобработки данных, обучения моделей, проведения экспериментов, построения графиков, а также итоговый отчёт, результаты экспериментов и файл `requirements.txt` с используемыми зависимостями. Наличие репозитория позволяет проследить структуру проекта и воспроизвести основные этапы исследования. Бинарные файлы обученных моделей и служебные файлы окружения не включались в репозиторий, поскольку они не являются необходимыми для анализа структуры проекта и могут быть заново получены запуском соответствующих скриптов.

3.3. Постановка экспериментов

Во всех экспериментах использовался датасет Rossmann с целевой переменной `Sales`.

Из обучающей выборки были исключены строки, соответствующие дням, когда магазин был закрыт: `Open = 0`. Такие наблюдения не отражают фактический потребительский спрос, поскольку продажи в эти дни равны нулю. Поэтому в дальнейшем задача рассматривается как прогнозирование продаж для дней, когда магазин открыт. После такой фильтрации признак `Open` фактически становится константным и не используется при интерпретации результатов как содержательный признак.

Разделение на обучающую и валидационную выборки выполнялось по времени:

- обучающая выборка: даты до 2015-06-01;
- валидационная выборка: даты начиная с 2015-06-01.

Категориальные признаки `StateHoliday`, `StoreType`, `Assortment` и `PromoInterval` кодировались методом прямого кодирования категориальных признаков (one-hot encoding). При кодировании использовался параметр `dummy_na=True`, поэтому для пропущенных значений создавался отдельный фиктивный признак.

После кодирования категориальных признаков оставшиеся пропуски в числовых признаках заполнялись нулём: `fillna(0)`. В данной работе это значение использовалось как техническое обозначение отсутствующей или неизвестной информации.

3.3.1. Формирование лаговых признаков и контроль утечки данных

Отдельное внимание было уделено лаговым признакам продаж, поскольку они позволяют учитывать зависимость текущего объёма продаж от предыдущих значений и отражать динамику спроса. Для каждого магазина лаговые признаки вычислялись внутри соответствующего временного ряда после сортировки наблюдений по `Store` и `Date`. Поскольку строки с закрытыми магазинами были исключены, индекс t в формулах ниже обозначает номер доступного наблюдения для конкретного магазина, а не обязательно соответствующий календарный день. При расчёте использовались только значения продаж, предшествующие текущему наблюдению:

$$\text{Sales_Lag1}_{s,t} = \text{Sales}_{s,t-1},$$

$$\text{Sales_Lag7}_{s,t} = \text{Sales}_{s,t-7},$$

$$\text{Sales_Rolling7}_{s,t} = \frac{1}{m_{s,t}} \sum_{k=1}^{m_{s,t}} \text{Sales}_{s,t-k}, \quad m_{s,t} = \min(7, t-1).$$

Здесь s обозначает магазин, а t — порядковый номер доступного наблюдения для данного магазина. Таким образом, `Sales_Lag1` соответствует предыдущему доступному наблюдению, а `Sales_Lag7` — седьмому предыдущему доступному наблюдению. При формировании признаков не использовались значения продаж за текущий день и будущие наблюдения. Эксперимент соответствует прогнозированию на один шаг вперёд (one-step-ahead forecasting): при прогнозировании очередного дня предполагается, что фактические продажи за предыдущие доступные дни уже известны. Для прогноза на несколько дней без обновления фактических продаж потребовалась бы отдельная рекурсивная схема расчёта лаговых признаков.

Следует также отметить, что признаки `DayOfWeek` и `dayofweek` содержательно описывают одно и то же. Первый признак присутствует в исходном датасете `Rossmann`, а второй был автоматически извлечён из поля `Date` средствами `pandas`. Они отличаются кодировкой: `DayOfWeek` принимает значения от 1 до 7, тогда как `dayofweek` — от 0 до 6. Поэтому при интерпретации важности признаков их следует рассматривать совместно как признаки дня недели. В более строгой версии предобработки один из этих признаков следовало бы исключить, чтобы уменьшить избыточность признакового пространства.

Признак `Store` использовался как идентификатор магазина, поэтому не интерпретировался как обычный числовой признак.

3.4. Метрики качества

Для оценки качества прогнозирования использовались три метрики: RMSPE, MAE и коэффициент детерминации R^2 .

Пусть y_i обозначает фактическое значение продаж, $\hat{y}_i$ — прогноз модели, $\bar{y}$ — среднее фактическое значение целевой переменной, а n — число наблюдений.

Основной метрикой сравнения была выбрана RMSPE:

$$\text{RMSPE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{y_i} \right)^2}.$$

Данная метрика измеряет относительную ошибку прогноза и поэтому подходит для сравнения магазинов с различным масштабом продаж.

При расчёте RMSPE учитывались только наблюдения с положительным фактическим значением продаж, поскольку метрика содержит деление на фактическое значение целевой переменной.

Дополнительно использовалась средняя абсолютная ошибка MAE:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

MAE показывает среднюю абсолютную ошибку прогноза в денежных единицах и является удобной для практической интерпретации.

Также рассчитывался коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Метрика R^2 показывает долю вариации целевой переменной, объясняемую моделью, и использовалась как вспомогательный показатель качества.

3.5. Гиперпараметры моделей

Для модели XGBoost использовались следующие параметры:

- `max_depth = 5`

Ограничивает максимальную глубину каждого дерева. Чем больше глубина, тем более сложные зависимости может учитывать модель, однако при слишком большом значении возрастает риск переобучения. В работе было выбрано оптимальное значение `max_depth = 5`.

- `learning_rate = 0.05`

Задаёт вклад каждого нового дерева в итоговый прогноз. Малое значение `learning_rate` делает обучение более плавным, что снижает риск переобучения, но требует большего числа boosting-итераций.

- `objective = reg:squarederror`

Задаёт функцию потерь для задачи регрессии.

- `eval_metric = rmse`

Указывает, что во время обучения качество модели на обучающей и валидационной выборках отслеживалось по RMSE.

- `num_boost_round = 3000`

Задаёт максимальное число boosting-итераций, то есть максимальное количество деревьев, которые может построить модель. Это верхняя граница, а не обязательно фактическое число использованных деревьев.

- `early_stopping_rounds = 50`

Задаёт число итераций без улучшения качества на валидационной выборке, после которого обучение останавливается.

- `seed = 42`

Фиксирует генератор случайных чисел, что позволяет при повторном запуске эксперимента с теми же данными, параметрами и версиями библиотек получать одинаковые результаты обучения.

Номер лучшей итерации при использовании early stopping сохранялся в служебном JSON-файле, однако в основную таблицу результатов он не включался, так как не является метрикой качества и неприменим к Random Forest.

Для модели Random Forest использовались параметры:

- `n_estimators = 100`

Задаёт количество деревьев в ансамбле. Большее число деревьев обычно повышает устойчивость модели и снижает разброс прогнозов, но увеличивает время обучения и размер модели.

- `max_depth = 15`

Ограничивает глубину деревьев. Это контролирует сложность модели и снижает риск переобучения. В отличие от XGBoost, в Random Forest деревья обучаются независимо, а случайность задаётся bootstrap-подвыборками наблюдений и случайным выбором признаков при разбиениях.

- `random_state = 42`

Аналогично `seed` в XGBoost.

- `n_jobs = -1`

Означает использование всех доступных ядер процессора для параллельного обучения деревьев. Этот параметр влияет на скорость обучения, но не является параметром качества модели.

4. Результаты

4.1. Сравнение моделей и вариантов признаков

Был выполнен перебор всех комбинаций групп признаков для трёх моделей: Linear Regression, Random Forest и XGBoost.

Во всех экспериментах использовался базовый набор признаков (`base`), включающий используемые исходные признаки из `train.csv` и `store.csv`, а также календарные признаки и фиктивные признаки, полученные методом прямого кодирования категориальных признаков (`one-hot encoding`):

- идентификатор магазина:

`Store;`

- исходные календарные и бинарные признаки из `train.csv`:

`DayOfWeek, Open, Promo, SchoolHoliday;`

- признаки конкуренции и промо-акций из `store.csv`:

`CompetitionDistance,
CompetitionOpenSinceMonth,
CompetitionOpenSinceYear,
Promo2,
Promo2SinceWeek,
Promo2SinceYear;`

- календарные признаки, извлечённые из `Date`:

`year, month, day, dayofweek, WeekOfYear, IsMonthEnd, IsFriday;`

- фиктивные признаки для категориальных признаков:

`StateHoliday_0, StateHoliday_a,
StateHoliday_b, StateHoliday_c,
StateHoliday_nan,
StoreType_a, StoreType_b, StoreType_c, StoreType_d, StoreType_nan,
Assortment_a, Assortment_b, Assortment_c, Assortment_nan,
PromoInterval_Jan, Apr, Jul, Oct,
PromoInterval_Feb, May, Aug, Nov,
PromoInterval_Mar, Jun, Sept, Dec,
PromoInterval_nan.`

В данной работе исторические признаки продаж рассматриваются как внутренние, поскольку они строятся на основе прошлых значений `Sales`. Под историческими признаками продаж далее понимаются лаговые признаки `Sales_Lag1`, `Sales_Lag7` и один признак скользящего среднего `Sales_Rolling7`.

Погодные данные, Google Trends и уровень безработицы относятся к внешним признакам, поскольку были получены из дополнительных источников, не входящих в исходные таблицы Rossmann. Праздничные признаки `PublicHoliday`, `BeforeHoliday` и `AfterHoliday` также были сформированы отдельно, поэтому они не объединяются с исходными признаками `StateHoliday` и `SchoolHoliday`.

Дополнительно перебирались следующие 6 групп признаков:

- погодные признаки (`weather`):

`temperature_mean`, `temperature_max`, `precipitation_sum`, `sunshine_sum`;

производные погодные признаки:

`TempRange`, `IsRainy`, `IsSunny`, `IsHot`, `IsCold`;

- Google Trends (`google_trends`):

`GoogleTrend`;

- уровень безработицы (`unemployment`):

`UnemploymentRate`;

- праздники (`holidays`):

`PublicHoliday`, `BeforeHoliday`, `AfterHoliday`;

- взаимодействия промо и погоды (`promo_weather`):

`Promo_Temperature`, `Promo_Sunny`, `Promo_Rainy`;

Данные признаки были рассчитаны как произведение признака наличия промо-акции `Promo` на соответствующие погодные признаки:

$$\text{Promo_Temperature} = \text{Promo} \cdot \text{temperature_mean},$$

$$\text{Promo_Sunny} = \text{Promo} \cdot \text{IsSunny},$$

$$\text{Promo_Rainy} = \text{Promo} \cdot \text{IsRainy}.$$

- лаговые признаки продаж (`lags`):

`Sales_Lag1`, `Sales_Lag7`, `Sales_Rolling7`.

Теоретически это даёт $2^6 = 64$ комбинаций, однако группа взаимодействий промо и погоды вычисляется через погодные признаки. Поэтому комбинации, где `promo_weather = true`, но `weather = false`, были исключены.

Итоговое число вариантов признаков составило $64 - 2^4 = 64 - 16 = 48$. Для каждого варианта были обучены три модели: Linear Regression, Random Forest и XGBoost. Таким образом, всего было проведено $48 \times 3 = 144$ эксперимента.

Варианты признаков были отсортированы по RMSPE, так как эта метрика отражает относительную ошибку прогноза и лучше подходит для сравнения качества моделей при разных уровнях продаж.

Например, если магазин имеет средний уровень продаж в 1 000 €, то ошибка в 500 € будет более существенной, тогда как для магазина со средним уровнем продаж в 20 000 € такая же абсолютная ошибка будет иметь меньший относительный масштаб. Поэтому метрика MAE, несмотря на удобную интерпретацию в евро, не была использована в качестве основной метрики ранжирования.

Метрика R^2 также не была выбрана в качестве основного критерия, поскольку она показывает долю вариации целевой переменной, объясняемую моделью, но не измеряет напрямую относительный размер ошибки прогноза. Иными словами, R^2 сравнивает ошибку модели с общим разбросом фактических значений относительно среднего, а не оценивает ошибку относительно каждого конкретного значения продаж. Поэтому при прогнозировании продаж, где наблюдения могут существенно различаться по масштабу, R^2 использовалась только как вспомогательная метрика.

4.1.1. Базовые прогнозы

Помимо моделей машинного обучения были рассчитаны простые базовые прогнозы, характерные для задач прогнозирования временных рядов. В качестве наивных прогнозов использовались продажи того же магазина из предыдущего доступного наблюдения и из седьмого предыдущего доступного наблюдения. Дополнительно были рассчитаны более содержательные агрегированные базовые прогнозы: средние продажи по магазину и средние продажи по паре магазин – день недели. Все средние значения рассчитывались только на обучающей выборке. Результаты приведены в таблице 1.

Таблица 1: Качество базовых прогнозов

Модель	RMSPE	MAE	R^2
Среднее по магазину и дню недели	0.2271	1276	0.7073
Naïve Lag-1	0.3094	1364	0.5445
Среднее по магазину	0.3177	1487	0.5952
Naïve Lag-7	0.4793	2434	0.0307

Сравнение показывает, что лучшие модели машинного обучения существенно превосходят базовые прогнозы по RMSPE. Наиболее сильным среди простых базовых вариантов оказался прогноз на основе средних продаж по магазину и дню недели, однако его RMSPE равна 0.2271, что заметно хуже результатов Random Forest и XGBoost. Это подтверждает, что для повышения качества прогнозирования необходимо использовать другие группы признаков.

4.1.2. Лучшие модели

Для повышения наглядности результатов сначала представлены десять лучших экспериментов по метрике RMSPE. Полная таблица результатов для Random Forest и XGBoost приведена ниже, а результаты перебора Linear Regression вынесены в отдельную таблицу. В столбце p указано количество признаков, использованных моделью после предобработки данных и кодирования категориальных признаков.

Таблица 2: Топ-10 экспериментов по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	RF	weather__holidays__lags	51	0.1429	683	0.8986
2	RF	weather__google_trends__holidays__lags	52	0.1432	683	0.8983
3	RF	holidays__lags	42	0.1433	687	0.8970
4	RF	google_trends__holidays__lags	43	0.1435	687	0.8969
5	RF	weather__unemployment__holidays__lags	52	0.1436	687	0.8974
6	RF	weather__google_trends__unemployment__holidays__lags	53	0.1438	687	0.8975
7	RF	unemployment__holidays__lags	43	0.1438	690	0.8969
8	RF	weather__google_trends__holidays__promo_weather__lags	55	0.1439	683	0.8983
9	XGB	holidays__lags	42	0.1439	698	0.8988
10	RF	weather__holidays__promo_weather__lags	54	0.1440	684	0.8981

Различия между лучшими моделями Random Forest и XGBoost оказались небольшими по абсолютной величине RMSPE: лучший Random Forest получил RMSPE 0.1429, а лучший XGBoost — 0.1439. В рамках выбранного временного разбиения, фиксированных гиперпараметров и рассмотренных наборов признаков Random Forest чаще занимал верхние позиции в ранжировании вариантов признаков.

Таблица 3: Ранжирование вариантов признаков по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	RF	weather__holidays__lags	51	0.1429	683	0.8986
2	RF	weather__google_trends__holidays__lags	52	0.1432	683	0.8983
3	RF	holidays__lags	42	0.1433	687	0.8970
4	RF	google_trends__holidays__lags	43	0.1435	687	0.8969
5	RF	weather__unemployment__holidays__lags	52	0.1436	687	0.8974
6	RF	weather__google_trends__unemployment__holidays__lags	53	0.1438	687	0.8975
7	RF	unemployment__holidays__lags	43	0.1438	690	0.8969
8	RF	weather__google_trends__holidays__promo_weather__lags	55	0.1439	683	0.8983
9	XGB	holidays__lags	42	0.1439	698	0.8988
10	RF	weather__holidays__promo_weather__lags	54	0.1440	684	0.8981
11	RF	google_trends__unemployment__holidays__lags	44	0.1440	690	0.8969
12	XGB	lags	39	0.1445	684	0.9024
13	RF	weather__lags	48	0.1445	693	0.8964
14	RF	weather__unemployment__holidays__promo_weather__lags	55	0.1446	687	0.8971
15	RF	weather__google_trends__lags	49	0.1446	693	0.8964
16	RF	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.1447	687	0.8972
17	RF	weather__google_trends__promo_weather__lags	52	0.1454	694	0.8961
18	RF	weather__promo_weather__lags	51	0.1456	693	0.8960
19	RF	weather__unemployment__lags	49	0.1459	699	0.8948
20	RF	weather__google_trends__unemployment__lags	50	0.1460	699	0.8949
21	RF	lags	39	0.1461	703	0.8934
22	RF	google_trends__lags	40	0.1462	703	0.8936
23	RF	weather__unemployment__promo_weather__lags	52	0.1468	699	0.8945
24	RF	weather__google_trends__unemployment__promo_weather__lags	53	0.1470	699	0.8945
25	XGB	google_trends__lags	40	0.1470	705	0.8976
26	RF	unemployment__lags	40	0.1472	708	0.8926
27	RF	google_trends__unemployment__lags	41	0.1474	708	0.8925
28	XGB	weather__unemployment__lags	49	0.1475	722	0.8896
29	XGB	weather__google_trends__lags	49	0.1481	728	0.8887
30	XGB	google_trends__holidays__lags	43	0.1488	733	0.8892
31	XGB	google_trends__unemployment__lags	41	0.1490	716	0.8944
32	XGB	weather__promo_weather__lags	51	0.1502	727	0.8890
33	XGB	weather__google_trends__unemployment__promo_weather__lags	53	0.1507	724	0.8897
34	XGB	weather__unemployment__holidays__lags	52	0.1507	749	0.8814
35	XGB	google_trends__unemployment__holidays__lags	44	0.1513	744	0.8849
36	XGB	unemployment__holidays__lags	43	0.1514	738	0.8865
37	XGB	weather__holidays__lags	51	0.1519	738	0.8842
38	XGB	weather__lags	48	0.1520	743	0.8837
39	XGB	weather__google_trends__holidays__lags	52	0.1524	734	0.8851
40	XGB	weather__google_trends__unemployment__lags	50	0.1525	740	0.8844

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
41	XGB	weather__unemployment__holidays__promo_weather__lags	55	0.1526	747	0.8810
42	XGB	weather__google_trends__unemployment__holidays__lags	53	0.1527	743	0.8829
43	XGB	unemployment__lags	40	0.1531	734	0.8877
44	XGB	weather__google_trends__promo_weather__lags	52	0.1536	738	0.8849
45	XGB	weather__google_trends__holidays__promo_weather__lags	55	0.1538	755	0.8801
46	XGB	weather__holidays__promo_weather__lags	54	0.1539	753	0.8812
47	XGB	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.1546	752	0.8800
48	XGB	unemployment__holidays	40	0.1569	724	0.8941
49	XGB	weather__unemployment__promo_weather__lags	52	0.1576	753	0.8808
50	XGB	holidays	39	0.1581	729	0.8904
51	XGB	google_trends__unemployment__holidays	41	0.1588	726	0.8934
52	XGB	google_trends__holidays	40	0.1597	731	0.8920
53	XGB	weather__holidays__promo_weather	51	0.1618	745	0.8846
54	XGB	weather__google_trends__unemployment__holidays	50	0.1652	758	0.8813
55	XGB	weather__holidays	48	0.1669	766	0.8749
56	XGB	weather__google_trends__holidays	49	0.1685	771	0.8730
57	XGB	weather__unemployment__holidays__promo_weather	52	0.1692	769	0.8736
58	XGB	weather	45	0.1714	775	0.8807
59	XGB	weather__google_trends__unemployment__holidays__promo_weather	53	0.1738	775	0.8689
60	XGB	weather__google_trends	46	0.1743	789	0.8763
61	XGB	weather__google_trends__promo_weather	49	0.1750	794	0.8768
62	XGB	weather__google_trends__holidays__promo_weather	52	0.1757	786	0.8622
63	XGB	weather__unemployment__promo_weather	49	0.1776	796	0.8757
64	XGB	weather__google_trends__unemployment	47	0.1790	788	0.8779
65	XGB	weather__unemployment	46	0.1793	800	0.8759
66	XGB	weather__google_trends__unemployment__promo_weather	50	0.1860	819	0.8687
67	XGB	base	36	0.1930	832	0.8666
68	XGB	weather__unemployment__holidays	49	0.1940	861	0.8474
69	XGB	unemployment	37	0.1947	833	0.8686
70	XGB	google_trends__unemployment	38	0.1975	835	0.8676
71	XGB	google_trends	37	0.2017	858	0.8580
72	XGB	weather__promo_weather	48	0.2025	879	0.8506
73	RF	weather	45	0.2499	1153	0.7170
74	RF	weather__promo_weather	48	0.2499	1153	0.7170
75	RF	weather__google_trends	46	0.2499	1153	0.7170
76	RF	weather__google_trends__promo_weather	49	0.2500	1153	0.7169
77	RF	base	36	0.2504	1145	0.7223
78	RF	google_trends	37	0.2505	1145	0.7222
79	RF	holidays	39	0.2558	1175	0.7097
80	RF	google_trends__holidays	40	0.2559	1176	0.7094

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
81	RF	weather__google_trends__holidays__promo_weather	52	0.2559	1184	0.7054
82	RF	weather__holidays	48	0.2560	1184	0.7055
83	RF	weather__holidays__promo_weather	51	0.2560	1184	0.7054
84	RF	weather__google_trends__holidays	49	0.2560	1184	0.7053
85	RF	google_trends__unemployment__holidays	41	0.2564	1175	0.7100
86	RF	unemployment__holidays	40	0.2564	1175	0.7099
87	RF	weather__unemployment__holidays__promo_weather	52	0.2564	1182	0.7062
88	RF	weather__unemployment__holidays	49	0.2564	1182	0.7061
89	RF	weather__google_trends__unemployment__holidays	50	0.2564	1182	0.7061
90	RF	weather__google_trends__unemployment__holidays__promo_weather	53	0.2564	1182	0.7061
91	RF	unemployment	37	0.2644	1161	0.7169
92	RF	google_trends__unemployment	38	0.2645	1161	0.7172
93	RF	weather__unemployment	46	0.2646	1169	0.7120
94	RF	weather__google_trends__unemployment__promo_weather	50	0.2646	1169	0.7119
95	RF	weather__unemployment__promo_weather	49	0.2646	1169	0.7118
96	RF	weather__google_trends__unemployment	47	0.2647	1170	0.7117

Таблица 4: Ранжирование вариантов признаков Linear Regression по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	LR	weather__unemployment__holidays__lags	52	0.2026	1012	0.7657
2	LR	weather__holidays__lags	51	0.2029	1012	0.7662
3	LR	weather__unemployment__holidays__promo_weather__lags	55	0.2034	1016	0.7643
4	LR	weather__holidays__promo_weather__lags	54	0.2038	1016	0.7648
5	LR	weather__unemployment__lags	49	0.2040	1010	0.7664
6	LR	weather__lags	48	0.2041	1010	0.7665
7	LR	weather__unemployment__promo_weather__lags	52	0.2048	1013	0.7652
8	LR	weather__promo_weather__lags	51	0.2049	1013	0.7653
9	LR	weather__google_trends__unemployment__holidays__lags	53	0.2074	1013	0.7668
10	LR	weather__google_trends__holidays__lags	52	0.2077	1012	0.7673
11	LR	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.2082	1016	0.7655
12	LR	weather__google_trends__holidays__promo_weather__lags	55	0.2085	1016	0.7660
13	LR	weather__google_trends__unemployment__lags	50	0.2087	1010	0.7676
14	LR	weather__google_trends__lags	49	0.2088	1010	0.7677
15	LR	weather__google_trends__unemployment__promo_weather__lags	53	0.2094	1013	0.7664
16	LR	weather__google_trends__promo_weather__lags	52	0.2095	1013	0.7665
17	LR	unemployment__holidays__lags	43	0.2124	1030	0.7658

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
18	LR	holidays__lags	42	0.2136	1032	0.7659
19	LR	unemployment__lags	40	0.2153	1033	0.7651
20	LR	lags	39	0.2160	1034	0.7651
21	LR	google_trends__unemployment__holidays__lags	44	0.2166	1029	0.7671
22	LR	google_trends__holidays__lags	43	0.2178	1031	0.7672
23	LR	google_trends__unemployment__lags	41	0.2195	1032	0.7664
24	LR	google_trends__lags	40	0.2202	1034	0.7664
25	LR	weather__holidays	48	0.4302	1914	0.2714
26	LR	weather__google_trends__holidays	49	0.4312	1914	0.2719
27	LR	weather__holidays__promo_weather	51	0.4319	1916	0.2700
28	LR	weather__google_trends__holidays__promo_weather	52	0.4328	1916	0.2705
29	LR	weather	45	0.4384	1923	0.2717
30	LR	weather__google_trends	46	0.4393	1923	0.2722
31	LR	weather__unemployment__holidays	49	0.4393	1925	0.2716
32	LR	weather__promo_weather	48	0.4400	1925	0.2704
33	LR	weather__google_trends__unemployment__holidays	50	0.4403	1925	0.2721
34	LR	weather__google_trends__promo_weather	49	0.4408	1925	0.2709
35	LR	weather__unemployment__holidays__promo_weather	52	0.4412	1928	0.2703
36	LR	weather__google_trends__unemployment__holidays__promo_weather	53	0.4422	1928	0.2708
37	LR	weather__unemployment	46	0.4499	1939	0.2702
38	LR	weather__google_trends__unemployment	47	0.4509	1940	0.2706
39	LR	weather__unemployment__promo_weather	49	0.4517	1942	0.2689
40	LR	weather__google_trends__unemployment__promo_weather	50	0.4526	1942	0.2694
41	LR	holidays	39	0.4617	1952	0.2706
42	LR	google_trends__holidays	40	0.4625	1952	0.2711
43	LR	unemployment__holidays	40	0.4713	1969	0.2666
44	LR	base	36	0.4717	1968	0.2672
45	LR	google_trends__unemployment__holidays	41	0.4722	1969	0.2671
46	LR	google_trends	37	0.4726	1968	0.2677
47	LR	unemployment	37	0.4842	1993	0.2603
48	LR	google_trends__unemployment	38	0.4850	1993	0.2607

4.2. Анализ важности признаков

Для выявления признаков, наиболее активно используемых моделями при формировании прогноза, был проведён анализ важности признаков. В качестве объектов анализа были выбраны модели, показавшие наилучшее качество прогнозирования на валидационной выборке по метрике RMSPE в рамках соответствующего класса.




Рис. 1: Топ-15 признаков Linear Regression по модулю коэффициента

Для линейной регрессии анализ проводился на основе модулей коэффициентов модели. Наибольшие по модулю коэффициенты соответствуют признакам, связанным с промо-акциями: `PromoInterval_nan`, `Promo2`, `Promo`, а также фиктивным признакам, кодирующим месячные интервалы участия магазина в промо-кампаниях `Promo2`. Кроме того, в число признаков с наибольшими по модулю коэффициентами вошли праздничные и календарные признаки: `AfterHoliday`, `BeforeHoliday`, `StateHoliday_a`, `StateHoliday_c`, `IsMonthEnd`, `IsFriday`.

Следует отметить, что интерпретация коэффициентов линейной регрессии имеет ряд ограничений. Абсолютная величина коэффициента зависит от масштаба соответствующего признака, а также от наличия корреляции между признаками. Поскольку признаки не приводились к единому масштабу, данный график не следует рассматривать как строгую оценку. Например, `Promo2` и `PromoInterval_nan` содержательно связаны между собой, поэтому высокие значения их коэффициентов не следует трактовать как полностью независимый вклад каждого признака в прогноз целевой переменной. Тем не менее анализ коэффициентов позволяет выявить группы признаков, наиболее активно используемые линейной моделью.




Рис. 2: Топ-15 важных признаков Random Forest

Для модели Random Forest важность признаков оценивалась на основе встроенной меры важности по уменьшению критерия разбиения (impurity-based feature importance), рассчитываемой по среднему уменьшению критерия MSE в деревьях ансамбля. Все важности в Random Forest нормируются так, что сумма важностей всех признаков равна 1. Наиболее важным для модели признаком оказался **Sales_Lag1**. Его вклад существенно превышает вклад остальных признаков, что свидетельствует о сильной связи прогноза текущего наблюдения с уровнем продаж в предыдущем доступном наблюдении.

Следующими по важности для Random Forest являются признаки средней истории продаж за 7 предыдущих наблюдений, промоакции, дня недели, календарные признаки и недельный лаг продаж.

При интерпретации данной диаграммы важно учитывать, что встроенная мера важности может быть смещена в пользу числовых признаков и признаков с большим числом возможных разбиений [14]. Более строгая проверка могла бы включать оценку важности признаков после их перемешивания на валидационной выборке, однако в данной работе она не проводилась.




Рис. 3: Средняя абсолютная важность признаков XGBoost по SHAP

Для модели XGBoost был применён SHAP-анализ. В отличие от встроенной в Random Forest меры важности признаков, SHAP-значения позволяют рассматривать не только средний вклад признака, но и направление этого вклада. Согласно графику средней абсолютной важности, наибольший вклад в прогноз XGBoost вносят признаки `Sales_Rolling7`, `Promo`, `Sales_Lag1`, `DayOfWeek`, `day`, `IsFriday`, `WeekOfYear` и `Sales_Lag7`. Таким образом, XGBoost, как и Random Forest, в первую очередь использует информацию о продажах за предыдущие доступные наблюдения, промоакциях и календарном периоде.




Рис. 4: Направление вклада признаков в прогноз XGBoost

Summary-график SHAP дополнительно показывает характер вклада признаков в прогноз. Высокие значения Sales_Rolling7, Sales_Lag1 и Sales_Lag7, как правило, смещают прогноз продаж вверх, что подтверждает наличие инерционности продаж. Признак Promo также преимущественно даёт положительный вклад в прогноз, поскольку проведение промоакций связано с ростом ожидаемых продаж. Для признака DayOfWeek различные значения дня недели могут как увеличивать, так и уменьшать прогноз, что указывает на различия в продажах между днями недели.

Сопоставление результатов для трёх моделей показывает, что наиболее информативными являются лаговые признаки продаж, признаки промоакций и календарные признаки. Внешние признаки, такие как погодные показатели и уровень безработицы, не вошли в число наиболее важных признаков для лучших древесных моделей. Это свидетельствует о том, что в рассматриваемой задаче их вклад в качество прогнозирования оказался ниже по сравнению с выше перечисленными признаками.

5. Обсуждение

5.1. Анализ результатов экспериментов

Главная закономерность, выявленная при сравнении вариантов признаков, состоит в определяющей роли лаговых признаков продаж. Для Random Forest переход от базового набора признаков к набору `lags` снизил RMSPE с 0.2504 до 0.1461, то есть примерно на 41.6%. Лучший вариант Random Forest, `weather__holidays__lags`, дополнительно снизил RMSPE до 0.1429. Аналогичная картина наблюдается и для XGBoost: базовая модель получила RMSPE 0.1930, тогда как вариант `holidays__lags` достиг RMSPE 0.1439.

Погодные признаки без лаговых признаков не дали устойчивого улучшения качества. Для Random Forest добавление только погодных признаков практически не изменило RMSPE относительно базового варианта: 0.2504 для `base` и 0.2499 для `weather`. Более того, комбинация `weather__holidays` для Random Forest оказалась хуже базового варианта по RMSPE: 0.2560 против 0.2504. Для XGBoost погодные признаки улучшали качество относительно `base`, однако основной прирост всё равно был связан именно с добавлением лагов.

Признак Google Trends также не показал устойчивого положительного эффекта. Например, для Random Forest варианты `weather` и `weather__google_trends` дали практически одинаковые значения RMSPE, а для XGBoost добавление Google Trends к погодным признакам ухудшило RMSPE с 0.1714 до 0.1743. Возможное объяснение состоит в том, что агрегированный поисковый интерес слабо связан с ежедневными продажами конкретных магазинов или уже частично отражается через календарные и исторические признаки.

Ограниченный вклад внешних данных может быть связан с уровнем их агрегации. Погодные данные были присоединены по федеральной земле и дате, поэтому они не отражают точные погодные условия около каждого магазина. Показатель безработицы использовался на месячном уровне и поэтому слабо описывает ежедневные колебания продаж. Google Trends отражает региональный поисковый интерес по запросу `rossmann`, но такой интерес может быть связан с брендом в целом, а не с фактическим спросом в конкретном магазине в конкретный день.

Таким образом, исходная гипотеза о возможной полезности внешних признаков подтвердилась только частично. Отдельные комбинации с погодными и праздничными признаками улучшали качество, однако основной прирост был связан с лаговыми признаками.

В данном исследовании XGBoost не превзошёл Random Forest по значению RMSPE, несмотря на сильные позиции градиентного бустинга в задачах табличного машинного обучения. Вероятно, это связано с фиксированными гиперпараметрами и высокой ролью лаговых, промо- и календарных признаков. Поэтому результат следует трактовать только в рамках выбранного разбиения данных, набора признаков и настроек моделей.

Линейная регрессия показала заметно худшее качество по сравнению с древесными ансамблями: лучший вариант Linear Regression получил RMSPE 0.2026, тогда как лучшие Random Forest и XGBoost находились около 0.143. Это указывает на наличие нелинейных зависимостей между признаками и продажами.

5.2. Интерпретация основных результатов

Основным результатом работы является эмпирическая оценка вклада различных групп признаков в качество прогнозирования дневных продаж магазинов Rossmann. В отличие от простого сравнения нескольких моделей, в исследовании проведён перебор 48 вариантов набора признаков для трёх классов моделей: Linear Regression, Random Forest и XGBoost.

Основные результаты исследования можно сформулировать следующим образом:

- установлено, что наибольший вклад в качество прогнозирования дают лаговые признаки продаж;
- показано, что внешние признаки без лаговых признаков дают ограниченный прирост качества и в ряде случаев не улучшают прогноз относительно базовых вариантов;
- выявлено, что в рамках заданных параметров и выбранного временного разбиения минимальное значение RMSPE было получено для Random Forest с набором признаков `weather__holidays__lags`;
- показано, что XGBoost даёт близкое к Random Forest качество, однако в проведённом переборе при фиксированных гиперпараметрах Random Forest чаще занимал верхние позиции;
- установлено, что использование максимального количества признаков не гарантирует наилучшего качества прогноза.

5.3. Практическая значимость

Полученные результаты имеют практическое значение для задач операционного планирования в розничной торговле. Точный прогноз дневных продаж может использоваться для планирования товарных запасов, снижения риска дефицита товаров, оптимизации поставок и распределения персонала между магазинами. Кроме того, оценка важности признаков показывает, какие источники данных целесообразно учитывать в первую очередь при построении прикладной модели прогнозирования.

С практической точки зрения наиболее полезным результатом является вывод о высокой важности истории продаж, промоакций и календарных признаков. Это означает, что при ограниченных ресурсах на сбор внешних данных приоритет следует отдавать их корректному формированию. Внешние источники, такие как погода, Google Trends и уровень безработицы, следует добавлять только после проверки их вклада на валидационной выборке.

5.4. Ограничения исследования и возможные улучшения

Проведённое исследование имеет ряд ограничений, которые необходимо учитывать при интерпретации результатов.

- Использовался один набор данных Rossmann Store Sales, поэтому выводы могут зависеть от специфики данной торговой сети и рассматриваемого периода.
- Для оценки качества применялось одно временное разбиение на обучающую и валидационную выборки, поэтому устойчивость различий между моделями не проверялась на нескольких периодах. Более строгая проверка могла бы включать последовательную временную валидацию на нескольких сдвигаемых периодах.
- Набор базовых прогнозов был расширен наивными лаговыми вариантами и средними продажами по магазину и дню недели. При этом более сложные статистические базовые модели, например экспоненциальное сглаживание или модели семейства ARIMA, в работе не рассматривались.
- Внешние признаки были агрегированы на уровне даты и региона, что могло сгладить локальные эффекты погоды и поискового интереса; показатель уровня безра-

ботицы использовался на месячном уровне. Кроме того, признак Google Trends имел недельную частоту и в текущей предобработке не распространялся на все дни соответствующей недели.

- В работе не моделировались возможные задержки публикации внешних данных. В таком случае можно было бы брать, например, последнее доступное значение на момент прогноза.
- Не проводился полный подбор гиперпараметров, из-за высокой вычислительной трудоёмкости и отсутствия цели в максимальной оптимизации каждой модели.
- Признак `Store` использовался как числовой, хотя содержательно он является категориальным. Кроме того, признаки `DayOfWeek` и `dayofweek` дублируют друг друга. В дальнейшем эти технические особенности предобработки следует устранить.
- Для Random Forest использовалась встроенная важность признаков, основанная на уменьшении критерия разбиения. Такая мера может быть смещена в пользу числовых признаков и признаков с большим числом возможных разбиений. Более строгая проверка могла бы включать важность по перемешиванию признаков (permutation importance) на валидационной выборке, однако это потребовало бы дополнительных вычислительных затрат и отдельного анализа коррелирующих признаков.
- В работе не рассматривались CatBoost, LightGBM и нейросетевые модели временных рядов, которые могут быть исследованы в дальнейшем.
- Для линейной регрессии ограничением является линейная зависимость фиктивных признаков. Это ограничение в меньшей степени относится к древесным моделям, таким как Random Forest и XGBoost, однако влияет на корректность интерпретации коэффициентов линейной модели.

6. Заключение

В результате проведённого исследования было установлено, что наибольший вклад в повышение качества прогнозирования дневных продаж вносят **лаговые признаки**, отражающие краткосрочную инерционность спроса. Это подтверждается тем, что все лучшие варианты моделей по метрике RMSPE включали группу `lags`.

Минимальное значение RMSPE среди всех протестированных конфигураций было получено для модели Random Forest с набором признаков `weather__holidays__lags`. Значение RMSPE составило 0.1429, MAE — 683 EUR, а коэффициент детерминации R^2 — 0.8986.

Исследовательская гипотеза подтвердилась частично. Внешние признаки не во всех конфигурациях улучшали качество прогнозирования, а основной вклад в снижение ошибки был связан с лаговыми признаками продаж. Поэтому включение внешних источников данных в модель требует предварительной эмпирической проверки на валидационной выборке.

Кроме того, результаты показали, что максимальное расширение набора признаков не гарантирует повышения качества прогнозирования. Более компактные наборы признаков, включающие лаги, праздничные и погодные признаки, оказались эффективнее некоторых расширенных комбинаций.

Таким образом, в рамках выбранного временного разбиения, фиксированных гиперпараметров и рассмотренных наборов признаков наиболее обоснованным кандидатом является

Random Forest с набором признаков `weather_holidays_lags`. Этот результат можно рассматривать как номинально лучший вариант внутри проведённого эксперимента, однако он не означает универсального превосходства Random Forest над XGBoost. Модели XGBoost показали близкое качество и могут быть дополнительно исследованы при более широком подборе гиперпараметров.

7. Список литературы

- [1] Rossmann Store Sales : dataset [Электронный ресурс] // Kaggle. — 2015. — URL: <https://www.kaggle.com/c/rossmann-store-sales> (дата обращения: 15.05.2026).
- [2] Fildes R., Ma S., Kolassa S. Retail forecasting: research and practice // International Journal of Forecasting. — 2022. — Vol. 38, no. 4. — P. 1283–1318. — DOI: 10.1016/j.ijforecast.2019.06.004.
- [3] Makridakis S., Spiliotis E., Assimakopoulos V. M5 accuracy competition: results, findings, and conclusions // International Journal of Forecasting. — 2022. — Vol. 38, no. 4. — P. 1346–1364. — DOI: 10.1016/j.ijforecast.2021.11.013.
- [4] Ma S., Fildes R., Huang T. Demand forecasting with high dimensional data: the case of SKU retail sales forecasting with intra- and inter-category promotional information // European Journal of Operational Research. — 2016. — Vol. 249, no. 1. — P. 245–257. — DOI: 10.1016/j.ejor.2015.08.029.
- [5] Rose N., Dolega L. It's the weather: quantifying the impact of weather on retail sales // Applied Spatial Analysis and Policy. — 2022. — Vol. 15, no. 1. — P. 189–214. — DOI: 10.1007/s12061-021-09397-0.
- [6] Choi H., Varian H. Predicting the present with Google Trends // The Economic Record. — 2012. — Vol. 88, no. s1. — P. 2–9. — DOI: 10.1111/j.1475-4932.2012.00809.x.
- [7] Hyndman R. J., Athanasopoulos G. Forecasting: principles and practice [Электронный ресурс]. — 3rd ed. — OTexts, 2021. — URL: <https://otexts.com/fpp3/> (дата обращения: 15.05.2026).
- [8] Friedman J. H. Greedy function approximation: a gradient boosting machine // The Annals of Statistics. — 2001. — Vol. 29, no. 5. — P. 1189–1232. — DOI: 10.1214/aos/1013203451.
- [9] Chen T., Guestrin C. XGBoost: a scalable tree boosting system // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — 2016. — P. 785–794. — DOI: 10.1145/2939672.2939785.
- [10] Breiman L. Random forests // Machine Learning. — 2001. — Vol. 45. — P. 5–32. — DOI: 10.1023/A:1010933404324.
- [11] Historical Weather API [Электронный ресурс] // Open-Meteo. — URL: <https://open-meteo.com/en/docs/historical-weather-api> (дата обращения: 15.05.2026).
- [12] Google Trends [Электронный ресурс] // Google. — URL: <https://trends.google.com/> (дата обращения: 15.05.2026).
- [13] Harmonized Unemployment Rate: All Persons for Germany [Электронный ресурс] // Federal Reserve Bank of St. Louis. — URL: <https://fred.stlouisfed.org/series/LRHUTTTTDEM156S> (дата обращения: 15.05.2026).

- [14] Strobl C., Boulesteix A.-L., Zeileis A., Hothorn T. Bias in random forest variable importance measures: illustrations, sources and a solution // BMC Bioinformatics. — 2007. — Vol. 8. — Article 25. — DOI: 10.1186/1471-2105-8-25.