

# Прикладные задачи анализа данных

Анализ вклада внутренних и внешних признаков в качество  
прогнозирования спроса в розничной сети

Медведев Максим Юрьевич, Радько Роман Олегович — БПМ255

15 мая 2026 г.

## Содержание

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Введение</b>                                                   | <b>2</b>  |
| 1.1      | Постановка задачи . . . . .                                       | 2         |
| 1.2      | Исходные данные . . . . .                                         | 2         |
| <b>2</b> | <b>Обзор литературы</b>                                           | <b>4</b>  |
| <b>3</b> | <b>Методы исследования</b>                                        | <b>4</b>  |
| 3.1      | Общая схема исследования . . . . .                                | 4         |
| 3.2      | Организация проекта и воспроизводимость экспериментов . . . . .   | 5         |
| 3.3      | Постановка экспериментов . . . . .                                | 7         |
| 3.3.1    | Формирование лаговых признаков и контроль утечки данных . . . . . | 8         |
| 3.4      | Метрики качества . . . . .                                        | 8         |
| 3.5      | Гиперпараметры моделей . . . . .                                  | 9         |
| <b>4</b> | <b>Результаты</b>                                                 | <b>10</b> |
| 4.1      | Сравнение моделей и вариантов признаков . . . . .                 | 10        |
| 4.1.1    | Наивные базовые модели . . . . .                                  | 12        |
| 4.1.2    | Лучшие модели . . . . .                                           | 13        |
| 4.2      | Анализ важности признаков . . . . .                               | 17        |
| <b>5</b> | <b>Обсуждение</b>                                                 | <b>21</b> |
| 5.1      | Анализ результатов экспериментов . . . . .                        | 22        |
| 5.2      | Интерпретация основных результатов . . . . .                      | 22        |
| 5.3      | Практическая значимость . . . . .                                 | 23        |
| 5.4      | Ограничения исследования . . . . .                                | 23        |
| <b>6</b> | <b>Заключение</b>                                                 | <b>24</b> |
| <b>7</b> | <b>Список литературы</b>                                          | <b>24</b> |

# 1. Введение

## 1.1. Постановка задачи

Актуальность исследования обусловлена необходимостью повышения точности прогнозирования спроса в розничной торговле. Ошибки прогноза дневных продаж могут приводить к избыточным запасам, дефициту товаров и снижению эффективности операционного планирования.

Объектом исследования являются дневные продажи магазинов сети Rossmann. Предметом исследования выступает вклад внутренних и внешних признаков в качество прогнозирования продаж. При этом исторические признаки продаж рассматриваются как часть внутренних признаков, поскольку они строятся на основе прошлых значений целевой переменной из исходного датасета.

Целью работы является оценка вклада дополнительных групп признаков в качество прогнозирования дневных продаж магазинов по сравнению с моделями, использующими базовый набор признаков датасета Rossmann Store Sales.

Для достижения поставленной цели решаются следующие задачи:

- подготовить исходные данные и объединить их со справочной информацией о магазинах;
- сформировать базовый набор внутренних признаков, включая исторические признаки продаж, и дополнительные внешние признаки;
- построить модели для различных наборов признаков;
- сравнить качество моделей с использованием метрик;
- определить группы признаков, вносящие наибольший вклад в качество прогнозирования.

Исследовательская гипотеза состоит в том, что добавление внешних признаков может улучшить качество прогнозирования по сравнению с базовой моделью. Дополнительно проверяется, какие группы признаков дают наибольший вклад в снижение ошибки прогноза.

Сравнение моделей проводится на основе временного разбиения данных. Модель обучается на более раннем временном интервале, а её качество оценивается на более позднем периоде. Такой подход позволяет приблизить эксперимент к реальной задаче прогнозирования будущих продаж.

## 1.2. Исходные данные

В качестве исходных данных используется готовый набор Rossmann Store Sales, содержащий историческую информацию о продажах в 1115 магазинах немецкой сети drogери [7].

Представленные в датасете признаки можно классифицировать по типу данных следующим образом:

- числовые;
- категориальные;

- бинарные;
- временные.

Таблица для обучения (`train.csv`) содержит следующие признаки:

- **Store** — идентификатор магазина;
- **DayOfWeek** — день недели (временной признак);
- **Date** — дата (временной признак);
- **Sales** — дневная выручка (числовой признак), являющаяся целевой переменной задачи прогнозирования;
- **Customers** — число покупателей (числовой признак);
- **Open** — был ли магазин открыт (бинарный признак);
- **Promo** — была ли в этот день акция (бинарный признак);
- **StateHoliday** — тип государственного праздника или его отсутствие (категориальный признак);
- **SchoolHoliday** — школьные каникулы (бинарный признак).

Признак **Customers** не использовался при обучении моделей, поскольку в реальной задаче прогнозирования будущих продаж количество покупателей заранее неизвестно. Использование этого признака могло бы привести к утечке информации, то есть к ситуации, когда модель получает данные, которые в реальной задаче заранее были бы неизвестны.

`test.csv` — файл, содержащий наблюдения, для которых необходимо спрогнозировать значения целевой переменной **Sales**. В настоящем исследовании данный файл не использовался, поскольку в нём отсутствуют фактические значения **Sales**. Оценка качества моделей проводилась на валидационной выборке, сформированной путём временного разделения данных из `train.csv`.

Таблица `store.csv` содержит справочную информацию по магазинам:

- **Store** — идентификатор магазина;
- **StoreType** — тип магазина (категориальный признак);
- **Assortment** — тип ассортимента (категориальный признак);
- **CompetitionDistance** — расстояние до ближайшего конкурента (числовой признак);
- **CompetitionOpenSinceMonth** — месяц, когда ближайший конкурент начал работать (временной признак);
- **CompetitionOpenSinceYear** — год, когда ближайший конкурент начал работать (временной признак);
- **Promo2** — участвует ли магазин в длительной повторяющейся промо-кампании (бинарный признак);
- **Promo2SinceWeek** — неделя, с которой началась **Promo2** (временной признак);
- **Promo2SinceYear** — год начала **Promo2** (временной признак);
- **PromoInterval** — месяцы проведения длительной промо-кампании **Promo2** (категориальный признак).

Также использовалась таблица `store_states.csv`, содержащая соответствие магазинов федеральным землям Германии. Она применялась для объединения данных о магазинах с внешними признаками, зависящими от региона.

## 2. Обзор литературы

Прогнозирование спроса в розничной торговле является сложной задачей, поскольку продажи зависят одновременно от календарных факторов, характеристик магазина, промо-акций, сезонности и внешней среды. В современных исследованиях и соревнованиях по прогнозированию спроса широко применяются методы машинного обучения для табличных данных, в том числе ансамбли решающих деревьев. Результаты соревнования M5 показывают, что в задачах розничного прогнозирования существенную роль играют признаки, отражающие историю спроса, календарь и промо-активность [8].

Связь погодных условий с продажами также рассматривается в прикладных исследованиях розничной торговли. Например, Н. Роуз и Л. Долега анализируют связь между погодными условиями и ежедневными продажами крупного ритейлера, используя, в том числе, методы случайного леса [10]. Такие исследования показывают, что погодные признаки потенциально могут быть полезны для прогнозирования спроса, однако величина и направление эффекта зависят от товарной категории, региона и типа магазина.

Отдельное направление связано с использованием поискового интереса как внешнего индикатора экономической активности. Х. Чой и Х. Вэриан показали, что данные Google Trends могут быть полезны для краткосрочного прогнозирования ряда экономических показателей, поскольку поисковые запросы отражают текущий интерес пользователей до публикации официальной статистики [3]. В контексте данной работы это обосновывает включение признака `GoogleTrend` в экспериментальный анализ, однако его вклад в качество прогнозирования продаж должен быть оценён эмпирически.

Таким образом, существующие исследования подтверждают целесообразность проверки внешних признаков в задачах прогнозирования спроса. При этом заранее нельзя утверждать, что каждый внешний источник данных улучшит качество модели. Его вклад зависит от временного горизонта прогноза, качества агрегации данных, типа товаров и уже имеющихся внутренних признаков.

## 3. Методы исследования

### 3.1. Общая схема исследования

После анализа структуры исходных данных задача была сформулирована как **задача регрессии**: по информации о магазине, календарной дате, промо-акциях, исторических продажах и дополнительных внешних признаках необходимо предсказать дневной объём продаж `Sales`. Поскольку данные имеют временную природу, при построении и оценке моделей важно сохранять хронологический порядок наблюдений и не перемешивать обучающую и валидационную выборки случайным образом.

В качестве основного направления решения были выбраны методы машинного обучения для табличных данных, в первую очередь ансамблевые методы на основе решающих деревьев. Такой выбор обусловлен тем, что продажи в розничной торговле могут зависеть от большого числа разнородных признаков: типа магазина, ассортимента, промо-акций, дня недели, праздников, сезонности и внешних условий. Кроме того, связь этих признаков с

продажами может быть нелинейной: например, эффект промо-акции может различаться для разных типов магазинов, дней недели или периодов года.

Одним из наиболее подходящих методов для такой постановки является градиентный бустинг над решающими деревьями. Метод градиентного бустинга был формализован в работе Дж. Фридмана, где бустинг рассматривается как последовательное построение аддитивной модели, минимизирующей функцию потерь [5]. В практической части работы использовалась реализация XGBoost, предложенная Т. Ченом и К. Гестрином [2]. Данный алгоритм хорошо подходит для задач с большим числом наблюдений и неоднородными признаками, что соответствует структуре рассматриваемого набора данных.

Также в качестве альтернативных моделей были рассмотрены линейная регрессия и случайный лес. Линейная регрессия использовалась как базовая интерпретируемая модель, позволяющая оценить качество простого линейного подхода. Метод случайного леса был систематически описан Л. Брейманом [1]; в данной работе он был выбран как ансамблевый нелинейный метод, позволяющий учитывать сложные зависимости между признаками без последовательного бустинга.

Выбор ансамблевых методов и лаговых признаков согласуется с практикой современных соревнований по прогнозированию спроса. Например, в соревновании M5, посвящённом прогнозированию розничных продаж, важную роль играли методы машинного обучения для табличных данных и признаки, описывающие историю спроса [8].

Общий ход исследования был следующим. Сначала исходные данные были очищены и объединены со справочной информацией о магазинах. Затем были сформированы дополнительные признаки: календарные признаки, фиктивные признаки для категориальных признаков, признаки праздников, погодные признаки, признак уровня безработицы, Google Trends, взаимодействия промо-акций и погоды, а также лаговые признаки продаж. Далее все признаки были разделены на несколько смысловых групп, что позволило провести серию экспериментов с различными наборами признаков.

Для оценки качества моделей исходная обучающая выборка была разделена на обучающую и валидационную части по времени. Наблюдения до 2015-06-01 использовались для обучения, а наблюдения начиная с 2015-06-01 — для валидации. Такой способ деления имитирует реальную задачу прогнозирования будущих продаж на основе исторических данных.

Качество моделей оценивалось с помощью трёх метрик: RMSPE, MAE и  $R^2$ . Основной метрикой сравнения была выбрана RMSPE, поскольку она измеряет относительную ошибку прогноза и учитывает различия в масштабе продаж между магазинами. После сравнения моделей и вариантов признаков для лучших моделей был проведён анализ важности признаков, позволяющий определить, какие признаки были наиболее важны для формирования прогноза.

### 3.2. Организация проекта и воспроизводимость экспериментов

Для обеспечения воспроизводимости экспериментов проект был организован следующим образом:

```
Sem/  
|-- data/  
|   |-- raw/  
|   |-- external/  
|   '-- cache/
```

```
|-- src/  
|   |-- data/  
|   '-- models/  
|-- outputs/  
|   |-- figures/  
|   |-- models/  
|   '-- reports/  
|-- notebooks/  
|-- requirements.txt  
 '-- README.md
```

В папке `data/raw/` хранятся исходные данные Rossmann:

- `train.csv`,
- `test.csv`,
- `store.csv`,
- `store_states.csv`.

В папке `data/external/` хранятся внешние данные:

- `weather_daytime.csv`,
- `googletrend_self.csv`,
- `unemployment_germany.csv`.

Погодные данные были получены через архивный API Open-Meteo [9] для столиц федеральных земель Германии и агрегированы до дневного уровня за рабочие часы магазинов. Данные Google Trends [6] были сформированы для запроса `rossmann` по федеральным землям Германии. Показатель безработицы был получен из FRED [4] как месячный показатель *Harmonized Unemployment Rate* для Германии. Внешние данные объединялись с основным датасетом по дате и региону; для месячного показателя безработицы значение месяца распространялось на все дни соответствующего месяца.

В папке `src/models/` находятся скрипты обучения моделей:

- `common.py` — содержит общие функции подготовки данных, формирования признаков и расчёта метрик;
- `model_runtime.py` — содержит вспомогательные функции для сохранения моделей, конфигураций и метаданных экспериментов;
- `feature_variant_search.py` — перебирает варианты признаков и обучает модели на разных наборах;
- `linear_regression.py` — обучает модель линейной регрессии на выбранном наборе признаков и сохраняет результаты;
- `random_forest.py` — обучает модель случайного леса на выбранном наборе признаков и строит график важности признаков;
- `xgboost_shap.py` — обучает модель XGBoost на выбранном наборе признаков и выполняет SHAP-анализ важности признаков.

В папке `outputs/models/` сохраняются обученные модели и метаданные:

- `linear_regression.pkl`,

- `random_forest.pkl`,
- `xgboost_shap_holidays_lags.json`,
- `feature_columns.json`,
- `preprocessing_config.json`.

В папке `outputs/reports/` сохраняются результаты экспериментов:

- `feature_variant_metrics.csv`,
- `feature_variant_metrics.json`,
- `feature_importance_xgboost.csv`,
- `experiments_summary.md`.

В папке `src/data/` находятся скрипты подготовки внешних данных:

- `weather.py`,
- `google_trends_parsing.py`,
- `unemployment.py`.

Актуальная версия проекта размещена в открытом репозитории GitHub: <https://github.com/alwaysnervous/rossman>.

Репозиторий содержит исходный код предобработки данных, обучения моделей, проведения экспериментов, построения графиков, а также итоговый отчёт, результаты экспериментов и файл `requirements.txt` с используемыми зависимостями. Наличие репозитория позволяет проследить структуру проекта и воспроизвести основные этапы исследования. Бинарные файлы обученных моделей и служебные файлы окружения не включались в репозиторий, поскольку они не являются необходимыми для анализа структуры проекта и могут быть заново получены запуском соответствующих скриптов.

### 3.3. Постановка экспериментов

Во всех экспериментах использовался датасет Rossmann с целевой переменной **Sales**.

Из обучающей выборки были исключены строки, соответствующие дням, когда магазин был закрыт: `Open = 0`. Такие наблюдения не отражают фактический потребительский спрос, поскольку продажи в эти дни равны нулю. Поэтому в дальнейшем задача рассматривается как прогнозирование продаж для дней, когда магазин открыт. После такой фильтрации признак `Open` фактически становится константным и не используется при интерпретации результатов как содержательно информативный признак.

Разделение на обучающую и валидационную выборки выполнялось по времени:

- обучающая выборка: даты до 2015-06-01;
- валидационная выборка: даты начиная с 2015-06-01.

Категориальные признаки `StateHoliday`, `StoreType`, `Assortment` и `PromoInterval` кодировались методом прямого кодирования категориальных признаков (one-hot encoding). При кодировании использовался параметр `dummy_na=True`, поэтому для пропущенных значений создавался отдельный фиктивный признак.

После кодирования категориальных признаков оставшиеся пропуски в числовых признаках заполнялись нулём: `fillna(0)`. В данной работе это значение использовалось как техническое обозначение отсутствующей или неизвестной информации.

### 3.3.1. Формирование лаговых признаков и контроль утечки данных

Отдельное внимание было уделено лаговым признакам продаж, поскольку они используют значения целевой переменной за предыдущие моменты времени. Для каждого магазина лаговые признаки вычислялись внутри соответствующего временного ряда после сортировки наблюдений по `Store` и `Date`. Поскольку строки с закрытыми магазинами были исключены, индекс  $t$  в формулах ниже обозначает номер доступного наблюдения для конкретного магазина, а не обязательно последовательный календарный день. При расчёте использовались только значения продаж, предшествующие текущему наблюдению:

$$\text{Sales\_Lag1}_{s,t} = \text{Sales}_{s,t-1},$$

$$\text{Sales\_Lag7}_{s,t} = \text{Sales}_{s,t-7},$$

$$\text{Sales\_Rolling7}_{s,t} = \frac{1}{m_{s,t}} \sum_{k=1}^{m_{s,t}} \text{Sales}_{s,t-k}, \quad m_{s,t} = \min(7, t-1).$$

Здесь  $s$  обозначает магазин, а  $t$  — порядковый номер доступного наблюдения для данного магазина. Таким образом, `Sales_Lag1` соответствует предыдущему доступному наблюдению, а `Sales_Lag7` — седьмому предыдущему доступному наблюдению. При формировании признаков не использовались значения продаж за текущий день и будущие наблюдения. Эксперимент соответствует постановке *one-step-ahead forecasting*: при прогнозировании очередного дня предполагается, что фактические продажи за предыдущие доступные дни уже известны. Для многодневного прогноза без обновления фактических продаж потребовалась бы отдельная рекурсивная схема расчёта лаговых признаков.

Следует также отметить, что признаки `DayOfWeek` и `dayofweek` содержательно описывают один и тот же календарный фактор. Первый признак присутствует в исходном датасете Rossmann, а второй был автоматически извлечён из поля `Date` средствами `pandas`. Они отличаются кодировкой: `DayOfWeek` принимает значения от 1 до 7, тогда как `dayofweek` — от 0 до 6. Поэтому при интерпретации важности признаков их следует рассматривать совместно как признаки дня недели.

## 3.4. Метрики качества

Для оценки качества прогнозирования использовались три метрики: RMSPE, MAE и коэффициент детерминации  $R^2$ . Пусть  $y_i$  обозначает фактическое значение продаж,  $\hat{y}_i$  — прогноз модели,  $\bar{y}$  — среднее фактическое значение целевой переменной, а  $n$  — число наблюдений.

Основной метрикой сравнения была выбрана RMSPE:

$$\text{RMSPE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left( \frac{y_i - \hat{y}_i}{y_i} \right)^2}.$$

Данная метрика измеряет относительную ошибку прогноза и поэтому подходит для сравнения магазинов с различным масштабом продаж.



При расчёте RMSPE учитывались только наблюдения с положительным фактическим значением продаж, поскольку метрика содержит деление на фактическое значение целевой переменной.

Дополнительно использовалась средняя абсолютная ошибка MAE:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

MAE показывает среднюю абсолютную ошибку прогноза в денежных единицах и является удобной для практической интерпретации.

Также рассчитывался коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Метрика  $R^2$  показывает долю вариации целевой переменной, объясняемую моделью, и использовалась как вспомогательный показатель качества.

### 3.5. Гиперпараметры моделей

Для модели XGBoost использовались следующие параметры:

- `max_depth = 5`

Ограничивает максимальную глубину каждого дерева. Чем больше глубина, тем более сложные зависимости может учитывать модель, однако при слишком большом значении возрастает риск переобучения. В работе было выбрано значение `max_depth = 5`, чтобы сохранить баланс между гибкостью модели и устойчивостью на валидационной выборке.

- `learning_rate = 0.05`

Задаёт вклад каждого нового дерева в итоговый прогноз. Малое значение `learning_rate` делает обучение более плавным, но требует большего числа boosting-итераций.

- `objective = reg:squarederror`

Задаёт функцию потерь для задачи регрессии.

- `eval_metric = rmse`

Указывает, что во время обучения качество модели на обучающей и валидационной выборках отслеживалось по RMSE.

- `num_boost_round = 3000`

Задаёт максимальное число boosting-итераций, то есть максимальное количество деревьев, которые может построить модель. Это верхняя граница, а не обязательно фактическое число использованных деревьев.

- `early_stopping_rounds = 50`

Задаёт число итераций без улучшения качества на валидационной выборке, после которого обучение останавливается.

- `seed = 42`

Фиксирует генератор случайных чисел, что позволяет при повторном запуске эксперимента с теми же данными, параметрами и версиями библиотек получать одинаковые результаты обучения.

Номер лучшей итерации при использовании `early stopping` сохранялся в служебном JSON-файле, однако в основную таблицу результатов он не включался, так как не является метрикой качества и неприменим к Random Forest.

Для модели Random Forest использовались параметры:

- `n_estimators = 100`

Задаёт количество деревьев в ансамбле. Большее число деревьев обычно повышает устойчивость модели и снижает разброс прогнозов, но увеличивает время обучения и размер модели.

- `max_depth = 15`

Ограничивает глубину деревьев. Это контролирует сложность модели и снижает риск переобучения. В отличие от XGBoost, в Random Forest деревья обучаются независимо, а случайность задаётся `bootstrap`-подвыборками наблюдений и случайным выбором признаков при разбиениях.

- `random_state = 42`

Фиксирует генератор случайных чисел, что позволяет при повторном запуске эксперимента с теми же данными, параметрами и версиями библиотек получать одинаковые результаты обучения.

- `n_jobs = -1`

Означает использование всех доступных ядер процессора для параллельного обучения деревьев. Этот параметр влияет на скорость обучения, но не является параметром качества модели.

## 4. Результаты

### 4.1. Сравнение моделей и вариантов признаков

Был выполнен систематический перебор комбинаций групп признаков для трёх моделей: Linear Regression, Random Forest и XGBoost.

Во всех экспериментах использовался базовый набор признаков (`base`), включающий используемые исходные признаки из `train.csv` и `store.csv`, а также календарные признаки и фиктивные признаки, полученные методом прямого кодирования категориальных признаков (`one-hot encoding`).

- идентификатор магазина:

`Store;`

- исходные календарные и бинарные признаки из `train.csv`:

`DayOfWeek, Open, Promo, SchoolHoliday;`

- признаки конкуренции и промо-программы из `store.csv`:

```
CompetitionDistance,  
CompetitionOpenSinceMonth,  
CompetitionOpenSinceYear,  
Promo2,  
Promo2SinceWeek,  
Promo2SinceYear;
```

- календарные признаки, извлечённые из `Date`:

```
year, month, day, dayofweek, WeekOfYear, IsMonthEnd, IsFriday;
```

- фиктивные признаки для категориальных признаков:

```
StateHoliday_0, StateHoliday_a,  
StateHoliday_b, StateHoliday_c,  
StateHoliday_nan,  
StoreType_a, StoreType_b, StoreType_c, StoreType_d, StoreType_nan,  
Assortment_a, Assortment_b, Assortment_c, Assortment_nan,  
PromoInterval_Jan, Apr, Jul, Oct,  
PromoInterval_Feb, May, Aug, Nov,  
PromoInterval_Mar, Jun, Sept, Dec,  
PromoInterval_nan.
```

Признак `Open` указан как часть исходного набора данных, однако после исключения закрытых дней он принимает одно значение и поэтому не рассматривается как содержательно важный признак при интерпретации моделей.

В данной работе исторические признаки продаж рассматриваются как внутренние, поскольку они строятся на основе прошлых значений `Sales`. Под историческими признаками продаж далее понимаются лаговые признаки `Sales_Lag1`, `Sales_Lag7` и один признак скользящего среднего `Sales_Rolling7`.

Погодные данные, Google Trends, уровень безработицы и праздничные признаки рассматриваются как внешние, так как они получены из источников вне исходных таблиц `Rossmann`.

Дополнительно перебирались следующие 6 групп признаков:

- погодные признаки (`weather`):

```
temperature_mean, temperature_max, precipitation_sum, sunshine_sum;
```

производные погодные признаки:

```
TempRange, IsRainy, IsSunny, IsHot, IsCold;
```

- Google Trends (`google_trends`):

```
GoogleTrend;
```

- уровень безработицы (`unemployment`):

```
UnemploymentRate;
```

- праздники (holidays):

PublicHoliday, BeforeHoliday, AfterHoliday;

- взаимодействия промо и погоды (promo\_weather):

Promo\_Temperature, Promo\_Sunny, Promo\_Rainy;

- лаговые признаки продаж (lags):

Sales\_Lag1, Sales\_Lag7, Sales\_Rolling7.

Теоретически это даёт  $2^6 = 64$  комбинаций, однако группа взаимодействий промо и погоды вычисляется через погодные признаки. Поэтому комбинации, где `promo_weather = true`, но `weather = false`, были исключены.

Итоговое число вариантов признаков составило  $64 - 2^4 = 64 - 16 = 48$ . Для каждого варианта были обучены три модели: Linear Regression, Random Forest и XGBoost. Таким образом, всего было проведено  $48 \times 3 = 144$  эксперимента.

Варианты признаков были отсортированы по RMSPE, так как эта метрика отражает относительную ошибку прогноза и лучше подходит для сравнения качества моделей при разных уровнях продаж.

Например, если магазин имеет средний уровень продаж в 1 000 €, то ошибка в 500 € будет более существенной, тогда как для магазина со средним уровнем продаж в 20 000 € такая же абсолютная ошибка будет иметь меньший относительный масштаб. Поэтому метрика MAE, несмотря на удобную интерпретацию в евро, не была использована в качестве основной метрики ранжирования.

Метрика  $R^2$  также не была выбрана в качестве основного критерия, поскольку она показывает долю вариации целевой переменной, объясняемую моделью, но не измеряет напрямую относительный размер ошибки прогноза. Иными словами,  $R^2$  сравнивает ошибку модели с общим разбросом фактических значений относительно среднего, а не оценивает ошибку относительно каждого конкретного значения продаж. Поэтому при прогнозировании продаж, где наблюдения могут существенно различаться по масштабу,  $R^2$  использовалась только как вспомогательная метрика.

#### 4.1.1. Наивные базовые модели

Помимо моделей машинного обучения был рассчитан простой наивный базовый прогноз, характерный для задач прогнозирования временных рядов. В качестве прогноза использовались только прошлые значения продаж того же магазина: продажи из предыдущего наблюдения и продажи из седьмого предыдущего наблюдения. Результаты приведены в таблице 1.

Таблица 1: Качество наивных базовых моделей

| Модель      | RMSPE  | MAE  | $R^2$  |
|-------------|--------|------|--------|
| Naive Lag-1 | 0.3094 | 1364 | 0.5445 |
| Naive Lag-7 | 0.4793 | 2434 | 0.0307 |

Сравнение показывает, что лучшие модели машинного обучения существенно превосходят наивные прогнозы по RMSPE. Это подтверждает, что для повышения качества прогнозирования недостаточно использовать только отдельные прошлые значения продаж: модели

дополнительно учитывают календарные признаки, промо-акции, характеристики магазинов и нелинейные зависимости между признаками.

#### 4.1.2. Лучшие модели

Для повышения наглядности результатов сначала представлены десять лучших экспериментов по метрике RMSPE. Полная таблица результатов для Random Forest и XGBoost приведена ниже, а результаты перебора Linear Regression вынесены в отдельную таблицу. В столбце  $p$  указано количество признаков, использованных моделью после предобработки данных и кодирования категориальных признаков.

Таблица 2: Топ-10 экспериментов по RMSPE

| Ранг | Модель | Набор признаков                                       | $p$ | RMSPE  | MAE | $R^2$  |
|------|--------|-------------------------------------------------------|-----|--------|-----|--------|
| 1    | RF     | weather__holidays__lags                               | 51  | 0.1429 | 683 | 0.8986 |
| 2    | RF     | weather__google_trends__holidays__lags                | 52  | 0.1432 | 683 | 0.8983 |
| 3    | RF     | holidays__lags                                        | 42  | 0.1433 | 687 | 0.8970 |
| 4    | RF     | google_trends__holidays__lags                         | 43  | 0.1435 | 687 | 0.8969 |
| 5    | RF     | weather__unemployment__holidays__lags                 | 52  | 0.1436 | 687 | 0.8974 |
| 6    | RF     | weather__google_trends__unemployment__holidays__lags  | 53  | 0.1438 | 687 | 0.8975 |
| 7    | RF     | unemployment__holidays__lags                          | 43  | 0.1438 | 690 | 0.8969 |
| 8    | RF     | weather__google_trends__holidays__promo_weather__lags | 55  | 0.1439 | 683 | 0.8983 |
| 9    | XGB    | holidays__lags                                        | 42  | 0.1439 | 698 | 0.8988 |
| 10   | RF     | weather__holidays__promo_weather__lags                | 54  | 0.1440 | 684 | 0.8981 |

Различия между лучшими моделями Random Forest и XGBoost оказались небольшими по абсолютной величине RMSPE: лучший Random Forest получил RMSPE 0.1429, а лучший XGBoost — 0.1439. В рамках выбранного временного разбиения, фиксированных гиперпараметров и рассмотренных наборов признаков Random Forest чаще занимал верхние позиции в ранжировании вариантов признаков.

Таблица 3: Ранжирование вариантов признаков по RMSPE

| Ранг | Модель | Набор признаков                                                     | $p$ | RMSPE  | MAE | $R^2$  |
|------|--------|---------------------------------------------------------------------|-----|--------|-----|--------|
| 1    | RF     | weather__holidays__lags                                             | 51  | 0.1429 | 683 | 0.8986 |
| 2    | RF     | weather__google_trends__holidays__lags                              | 52  | 0.1432 | 683 | 0.8983 |
| 3    | RF     | holidays__lags                                                      | 42  | 0.1433 | 687 | 0.8970 |
| 4    | RF     | google_trends__holidays__lags                                       | 43  | 0.1435 | 687 | 0.8969 |
| 5    | RF     | weather__unemployment__holidays__lags                               | 52  | 0.1436 | 687 | 0.8974 |
| 6    | RF     | weather__google_trends__unemployment__holidays__lags                | 53  | 0.1438 | 687 | 0.8975 |
| 7    | RF     | unemployment__holidays__lags                                        | 43  | 0.1438 | 690 | 0.8969 |
| 8    | RF     | weather__google_trends__holidays__promo_weather__lags               | 55  | 0.1439 | 683 | 0.8983 |
| 9    | XGB    | holidays__lags                                                      | 42  | 0.1439 | 698 | 0.8988 |
| 10   | RF     | weather__holidays__promo_weather__lags                              | 54  | 0.1440 | 684 | 0.8981 |
| 11   | RF     | google_trends__unemployment__holidays__lags                         | 44  | 0.1440 | 690 | 0.8969 |
| 12   | XGB    | lags                                                                | 39  | 0.1445 | 684 | 0.9024 |
| 13   | RF     | weather__lags                                                       | 48  | 0.1445 | 693 | 0.8964 |
| 14   | RF     | weather__unemployment__holidays__promo_weather__lags                | 55  | 0.1446 | 687 | 0.8971 |
| 15   | RF     | weather__google_trends__lags                                        | 49  | 0.1446 | 693 | 0.8964 |
| 16   | RF     | weather__google_trends__unemployment__holidays__promo_weather__lags | 56  | 0.1447 | 687 | 0.8972 |
| 17   | RF     | weather__google_trends__promo_weather__lags                         | 52  | 0.1454 | 694 | 0.8961 |
| 18   | RF     | weather__promo_weather__lags                                        | 51  | 0.1456 | 693 | 0.8960 |
| 19   | RF     | weather__unemployment__lags                                         | 49  | 0.1459 | 699 | 0.8948 |
| 20   | RF     | weather__google_trends__unemployment__lags                          | 50  | 0.1460 | 699 | 0.8949 |
| 21   | RF     | lags                                                                | 39  | 0.1461 | 703 | 0.8934 |
| 22   | RF     | google_trends__lags                                                 | 40  | 0.1462 | 703 | 0.8936 |
| 23   | RF     | weather__unemployment__promo_weather__lags                          | 52  | 0.1468 | 699 | 0.8945 |
| 24   | RF     | weather__google_trends__unemployment__promo_weather__lags           | 53  | 0.1470 | 699 | 0.8945 |
| 25   | XGB    | google_trends__lags                                                 | 40  | 0.1470 | 705 | 0.8976 |
| 26   | RF     | unemployment__lags                                                  | 40  | 0.1472 | 708 | 0.8926 |
| 27   | RF     | google_trends__unemployment__lags                                   | 41  | 0.1474 | 708 | 0.8925 |
| 28   | XGB    | weather__unemployment__lags                                         | 49  | 0.1475 | 722 | 0.8896 |
| 29   | XGB    | weather__google_trends__lags                                        | 49  | 0.1481 | 728 | 0.8887 |
| 30   | XGB    | google_trends__holidays__lags                                       | 43  | 0.1488 | 733 | 0.8892 |
| 31   | XGB    | google_trends__unemployment__lags                                   | 41  | 0.1490 | 716 | 0.8944 |
| 32   | XGB    | weather__promo_weather__lags                                        | 51  | 0.1502 | 727 | 0.8890 |
| 33   | XGB    | weather__google_trends__unemployment__promo_weather__lags           | 53  | 0.1507 | 724 | 0.8897 |
| 34   | XGB    | weather__unemployment__holidays__lags                               | 52  | 0.1507 | 749 | 0.8814 |
| 35   | XGB    | google_trends__unemployment__holidays__lags                         | 44  | 0.1513 | 744 | 0.8849 |
| 36   | XGB    | unemployment__holidays__lags                                        | 43  | 0.1514 | 738 | 0.8865 |
| 37   | XGB    | weather__holidays__lags                                             | 51  | 0.1519 | 738 | 0.8842 |
| 38   | XGB    | weather__lags                                                       | 48  | 0.1520 | 743 | 0.8837 |
| 39   | XGB    | weather__google_trends__holidays__lags                              | 52  | 0.1524 | 734 | 0.8851 |
| 40   | XGB    | weather__google_trends__unemployment__lags                          | 50  | 0.1525 | 740 | 0.8844 |

| Ранг | Модель | Набор признаков                                                     | $p$ | RMSPE  | MAE  | $R^2$  |
|------|--------|---------------------------------------------------------------------|-----|--------|------|--------|
| 41   | XGB    | weather__unemployment__holidays__promo_weather__lags                | 55  | 0.1526 | 747  | 0.8810 |
| 42   | XGB    | weather__google_trends__unemployment__holidays__lags                | 53  | 0.1527 | 743  | 0.8829 |
| 43   | XGB    | unemployment__lags                                                  | 40  | 0.1531 | 734  | 0.8877 |
| 44   | XGB    | weather__google_trends__promo_weather__lags                         | 52  | 0.1536 | 738  | 0.8849 |
| 45   | XGB    | weather__google_trends__holidays__promo_weather__lags               | 55  | 0.1538 | 755  | 0.8801 |
| 46   | XGB    | weather__holidays__promo_weather__lags                              | 54  | 0.1539 | 753  | 0.8812 |
| 47   | XGB    | weather__google_trends__unemployment__holidays__promo_weather__lags | 56  | 0.1546 | 752  | 0.8800 |
| 48   | XGB    | unemployment__holidays                                              | 40  | 0.1569 | 724  | 0.8941 |
| 49   | XGB    | weather__unemployment__promo_weather__lags                          | 52  | 0.1576 | 753  | 0.8808 |
| 50   | XGB    | holidays                                                            | 39  | 0.1581 | 729  | 0.8904 |
| 51   | XGB    | google_trends__unemployment__holidays                               | 41  | 0.1588 | 726  | 0.8934 |
| 52   | XGB    | google_trends__holidays                                             | 40  | 0.1597 | 731  | 0.8920 |
| 53   | XGB    | weather__holidays__promo_weather                                    | 51  | 0.1618 | 745  | 0.8846 |
| 54   | XGB    | weather__google_trends__unemployment__holidays                      | 50  | 0.1652 | 758  | 0.8813 |
| 55   | XGB    | weather__holidays                                                   | 48  | 0.1669 | 766  | 0.8749 |
| 56   | XGB    | weather__google_trends__holidays                                    | 49  | 0.1685 | 771  | 0.8730 |
| 57   | XGB    | weather__unemployment__holidays__promo_weather                      | 52  | 0.1692 | 769  | 0.8736 |
| 58   | XGB    | weather                                                             | 45  | 0.1714 | 775  | 0.8807 |
| 59   | XGB    | weather__google_trends__unemployment__holidays__promo_weather       | 53  | 0.1738 | 775  | 0.8689 |
| 60   | XGB    | weather__google_trends                                              | 46  | 0.1743 | 789  | 0.8763 |
| 61   | XGB    | weather__google_trends__promo_weather                               | 49  | 0.1750 | 794  | 0.8768 |
| 62   | XGB    | weather__google_trends__holidays__promo_weather                     | 52  | 0.1757 | 786  | 0.8622 |
| 63   | XGB    | weather__unemployment__promo_weather                                | 49  | 0.1776 | 796  | 0.8757 |
| 64   | XGB    | weather__google_trends__unemployment                                | 47  | 0.1790 | 788  | 0.8779 |
| 65   | XGB    | weather__unemployment                                               | 46  | 0.1793 | 800  | 0.8759 |
| 66   | XGB    | weather__google_trends__unemployment__promo_weather                 | 50  | 0.1860 | 819  | 0.8687 |
| 67   | XGB    | base                                                                | 36  | 0.1930 | 832  | 0.8666 |
| 68   | XGB    | weather__unemployment__holidays                                     | 49  | 0.1940 | 861  | 0.8474 |
| 69   | XGB    | unemployment                                                        | 37  | 0.1947 | 833  | 0.8686 |
| 70   | XGB    | google_trends__unemployment                                         | 38  | 0.1975 | 835  | 0.8676 |
| 71   | XGB    | google_trends                                                       | 37  | 0.2017 | 858  | 0.8580 |
| 72   | XGB    | weather__promo_weather                                              | 48  | 0.2025 | 879  | 0.8506 |
| 73   | RF     | weather                                                             | 45  | 0.2499 | 1153 | 0.7170 |
| 74   | RF     | weather__promo_weather                                              | 48  | 0.2499 | 1153 | 0.7170 |
| 75   | RF     | weather__google_trends                                              | 46  | 0.2499 | 1153 | 0.7170 |
| 76   | RF     | weather__google_trends__promo_weather                               | 49  | 0.2500 | 1153 | 0.7169 |
| 77   | RF     | base                                                                | 36  | 0.2504 | 1145 | 0.7223 |
| 78   | RF     | google_trends                                                       | 37  | 0.2505 | 1145 | 0.7222 |
| 79   | RF     | holidays                                                            | 39  | 0.2558 | 1175 | 0.7097 |
| 80   | RF     | google_trends__holidays                                             | 40  | 0.2559 | 1176 | 0.7094 |

| Ранг | Модель | Набор признаков                                               | $p$ | RMSPE  | MAE  | $R^2$  |
|------|--------|---------------------------------------------------------------|-----|--------|------|--------|
| 81   | RF     | weather__google_trends__holidays__promo_weather               | 52  | 0.2559 | 1184 | 0.7054 |
| 82   | RF     | weather__holidays                                             | 48  | 0.2560 | 1184 | 0.7055 |
| 83   | RF     | weather__holidays__promo_weather                              | 51  | 0.2560 | 1184 | 0.7054 |
| 84   | RF     | weather__google_trends__holidays                              | 49  | 0.2560 | 1184 | 0.7053 |
| 85   | RF     | google_trends__unemployment__holidays                         | 41  | 0.2564 | 1175 | 0.7100 |
| 86   | RF     | unemployment__holidays                                        | 40  | 0.2564 | 1175 | 0.7099 |
| 87   | RF     | weather__unemployment__holidays__promo_weather                | 52  | 0.2564 | 1182 | 0.7062 |
| 88   | RF     | weather__unemployment__holidays                               | 49  | 0.2564 | 1182 | 0.7061 |
| 89   | RF     | weather__google_trends__unemployment__holidays                | 50  | 0.2564 | 1182 | 0.7061 |
| 90   | RF     | weather__google_trends__unemployment__holidays__promo_weather | 53  | 0.2564 | 1182 | 0.7061 |
| 91   | RF     | unemployment                                                  | 37  | 0.2644 | 1161 | 0.7169 |
| 92   | RF     | google_trends__unemployment                                   | 38  | 0.2645 | 1161 | 0.7172 |
| 93   | RF     | weather__unemployment                                         | 46  | 0.2646 | 1169 | 0.7120 |
| 94   | RF     | weather__google_trends__unemployment__promo_weather           | 50  | 0.2646 | 1169 | 0.7119 |
| 95   | RF     | weather__unemployment__promo_weather                          | 49  | 0.2646 | 1169 | 0.7118 |
| 96   | RF     | weather__google_trends__unemployment                          | 47  | 0.2647 | 1170 | 0.7117 |

Таблица 4: Ранжирование вариантов признаков Linear Regression по RMSPE

| Ранг | Модель | Набор признаков                                                     | $p$ | RMSPE  | MAE  | $R^2$  |
|------|--------|---------------------------------------------------------------------|-----|--------|------|--------|
| 1    | LR     | weather__unemployment__holidays__lags                               | 52  | 0.2026 | 1012 | 0.7657 |
| 2    | LR     | weather__holidays__lags                                             | 51  | 0.2029 | 1012 | 0.7662 |
| 3    | LR     | weather__unemployment__holidays__promo_weather__lags                | 55  | 0.2034 | 1016 | 0.7643 |
| 4    | LR     | weather__holidays__promo_weather__lags                              | 54  | 0.2038 | 1016 | 0.7648 |
| 5    | LR     | weather__unemployment__lags                                         | 49  | 0.2040 | 1010 | 0.7664 |
| 6    | LR     | weather__lags                                                       | 48  | 0.2041 | 1010 | 0.7665 |
| 7    | LR     | weather__unemployment__promo_weather__lags                          | 52  | 0.2048 | 1013 | 0.7652 |
| 8    | LR     | weather__promo_weather__lags                                        | 51  | 0.2049 | 1013 | 0.7653 |
| 9    | LR     | weather__google_trends__unemployment__holidays__lags                | 53  | 0.2074 | 1013 | 0.7668 |
| 10   | LR     | weather__google_trends__holidays__lags                              | 52  | 0.2077 | 1012 | 0.7673 |
| 11   | LR     | weather__google_trends__unemployment__holidays__promo_weather__lags | 56  | 0.2082 | 1016 | 0.7655 |
| 12   | LR     | weather__google_trends__holidays__promo_weather__lags               | 55  | 0.2085 | 1016 | 0.7660 |
| 13   | LR     | weather__google_trends__unemployment__lags                          | 50  | 0.2087 | 1010 | 0.7676 |
| 14   | LR     | weather__google_trends__lags                                        | 49  | 0.2088 | 1010 | 0.7677 |
| 15   | LR     | weather__google_trends__unemployment__promo_weather__lags           | 53  | 0.2094 | 1013 | 0.7664 |
| 16   | LR     | weather__google_trends__promo_weather__lags                         | 52  | 0.2095 | 1013 | 0.7665 |
| 17   | LR     | unemployment__holidays__lags                                        | 43  | 0.2124 | 1030 | 0.7658 |



| Ранг | Модель | Набор признаков                                               | $p$ | RMSPE  | MAE  | $R^2$  |
|------|--------|---------------------------------------------------------------|-----|--------|------|--------|
| 18   | LR     | holidays__lags                                                | 42  | 0.2136 | 1032 | 0.7659 |
| 19   | LR     | unemployment__lags                                            | 40  | 0.2153 | 1033 | 0.7651 |
| 20   | LR     | lags                                                          | 39  | 0.2160 | 1034 | 0.7651 |
| 21   | LR     | google_trends__unemployment__holidays__lags                   | 44  | 0.2166 | 1029 | 0.7671 |
| 22   | LR     | google_trends__holidays__lags                                 | 43  | 0.2178 | 1031 | 0.7672 |
| 23   | LR     | google_trends__unemployment__lags                             | 41  | 0.2195 | 1032 | 0.7664 |
| 24   | LR     | google_trends__lags                                           | 40  | 0.2202 | 1034 | 0.7664 |
| 25   | LR     | weather__holidays                                             | 48  | 0.4302 | 1914 | 0.2714 |
| 26   | LR     | weather__google_trends__holidays                              | 49  | 0.4312 | 1914 | 0.2719 |
| 27   | LR     | weather__holidays__promo_weather                              | 51  | 0.4319 | 1916 | 0.2700 |
| 28   | LR     | weather__google_trends__holidays__promo_weather               | 52  | 0.4328 | 1916 | 0.2705 |
| 29   | LR     | weather                                                       | 45  | 0.4384 | 1923 | 0.2717 |
| 30   | LR     | weather__google_trends                                        | 46  | 0.4393 | 1923 | 0.2722 |
| 31   | LR     | weather__unemployment__holidays                               | 49  | 0.4393 | 1925 | 0.2716 |
| 32   | LR     | weather__promo_weather                                        | 48  | 0.4400 | 1925 | 0.2704 |
| 33   | LR     | weather__google_trends__unemployment__holidays                | 50  | 0.4403 | 1925 | 0.2721 |
| 34   | LR     | weather__google_trends__promo_weather                         | 49  | 0.4408 | 1925 | 0.2709 |
| 35   | LR     | weather__unemployment__holidays__promo_weather                | 52  | 0.4412 | 1928 | 0.2703 |
| 36   | LR     | weather__google_trends__unemployment__holidays__promo_weather | 53  | 0.4422 | 1928 | 0.2708 |
| 37   | LR     | weather__unemployment                                         | 46  | 0.4499 | 1939 | 0.2702 |
| 38   | LR     | weather__google_trends__unemployment                          | 47  | 0.4509 | 1940 | 0.2706 |
| 39   | LR     | weather__unemployment__promo_weather                          | 49  | 0.4517 | 1942 | 0.2689 |
| 40   | LR     | weather__google_trends__unemployment__promo_weather           | 50  | 0.4526 | 1942 | 0.2694 |
| 41   | LR     | holidays                                                      | 39  | 0.4617 | 1952 | 0.2706 |
| 42   | LR     | google_trends__holidays                                       | 40  | 0.4625 | 1952 | 0.2711 |
| 43   | LR     | unemployment__holidays                                        | 40  | 0.4713 | 1969 | 0.2666 |
| 44   | LR     | base                                                          | 36  | 0.4717 | 1968 | 0.2672 |
| 45   | LR     | google_trends__unemployment__holidays                         | 41  | 0.4722 | 1969 | 0.2671 |
| 46   | LR     | google_trends                                                 | 37  | 0.4726 | 1968 | 0.2677 |
| 47   | LR     | unemployment                                                  | 37  | 0.4842 | 1993 | 0.2603 |
| 48   | LR     | google_trends__unemployment                                   | 38  | 0.4850 | 1993 | 0.2607 |

## 4.2. Анализ важности признаков

Для выявления признаков с наибольшей модельной важностью был проведён анализ важности признаков. В качестве объектов анализа были выбраны модели, показавшие наилучшее качество прогнозирования на валидационной выборке (по метрике RMSPE) в рамках соответствующего класса моделей: линейной регрессии, случайного леса и XGBoost.




Рис. 1: Топ-15 важных признаков Linear Regression

Для линейной регрессии анализ проводился на основе модулей коэффициентов модели, то есть величин  $|b_j|$ . Наибольшие по модулю коэффициенты соответствуют признакам, связанным с промо-активностью: `PromoInterval_nan`, `Promo2`, `Promo`, а также фиктивным признакам, кодирующим месячные интервалы участия магазина в промо-кампаниях `Promo2`. Кроме того, в число признаков с наибольшими по модулю коэффициентами вошли праздничные и календарные признаки: `AfterHoliday`, `BeforeHoliday`, `StateHoliday_a`, `StateHoliday_c`, `IsMonthEnd`, `IsFriday`. Эти признаки наиболее активно используются линейной моделью при формировании прогноза.

Следует отметить, что интерпретация коэффициентов линейной регрессии имеет ряд ограничений. Абсолютная величина коэффициента зависит от масштаба соответствующего признака, а также от наличия корреляции между признаками. Например, `Promo2` и `PromoInterval_nan` содержательно связаны между собой, поэтому высокие значения их коэффициентов не следует трактовать как полностью независимый вклад каждого признака в прогноз целевой переменной. Тем не менее анализ коэффициентов позволяет выявить группы признаков, наиболее активно используемые линейной моделью.




Рис. 2: Топ-15 важных признаков Random Forest

Для модели Random Forest важность признаков оценивалась на основе встроенной меры важности, рассчитываемой по уменьшению ошибки в деревьях ансамбля. Все важности в Random Forest нормируются так, что сумма важностей всех признаков равна 1. Наиболее важным для модели признаком оказался **Sales\_Lag1**, отражающий объём продаж в предыдущем доступном наблюдении для данного магазина. Его вклад существенно превышает вклад остальных признаков, что свидетельствует о сильной связи прогноза текущего наблюдения с уровнем продаж в предыдущем доступном наблюдении.

Следующими по модельной важности для Random Forest являются сглаженная история продаж за предыдущие наблюдения, промо-акция, признаки дня недели, календарные признаки и недельный лаг продаж. Это показывает, что модель использует как краткосрочную историю продаж, так и регулярные календарные закономерности. Наличие промо-акции также входит в число ключевых факторов, что согласуется с экономической логикой задачи прогнозирования розничных продаж.




Рис. 3: Средняя абсолютная важность признаков XGBoost по SHAP

Для модели XGBoost был применён SHAP-анализ, позволяющий оценить вклад каждого признака в индивидуальные прогнозы модели. В отличие от обычной важности признаков, SHAP-значения позволяют рассматривать не только среднюю силу вклада признака, но и **направление этого вклада**. Согласно графику средней абсолютной важности, наибольший вклад в прогноз XGBoost вносят признаки **Sales\_Rolling7**, **Promo**, **Sales\_Lag1**, **DayOfWeek**, **day**, **IsFriday**, **WeekOfYear** и **Sales\_Lag7**. Таким образом, XGBoost, как и Random Forest, в первую очередь использует информацию о продажах за предыдущие доступные наблюдения, промо-активности и календарных закономерностях.




Рис. 4: Направление вклада признаков в прогноз XGBoost

Summary-график SHAP дополнительно показывает характер вклада признаков в прогноз. Высокие значения Sales\_Rolling7, Sales\_Lag1 и Sales\_Lag7, как правило, смещают прогноз продаж вверх, что подтверждает наличие инерционности продаж. Признак Promo также преимущественно даёт положительный вклад в прогноз, поскольку проведение промо-акций связано с ростом ожидаемых продаж. Для признака DayOfWeek наблюдается более сложная структура вклада: различные значения дня недели могут как увеличивать, так и уменьшать прогноз, что отражает недельную сезонность покупательского поведения.

Сопоставление результатов для трёх моделей показывает, что наиболее информативными являются три группы признаков: лаговые признаки продаж, признаки промо-акций и календарные признаки. Данные группы признаков имеют высокую модельную важность как для линейной модели, так и для ансамблевых древесных алгоритмов. Внешние признаки, такие как погодные показатели и уровень безработицы, не вошли в число наиболее важных признаков для лучших древесных моделей. Это свидетельствует о том, что в рассматриваемой задаче их вклад в качество прогнозирования оказался ниже по сравнению с историей продаж, промо-акциями и календарными закономерностями.

## 5. Обсуждение

### 5.1. Анализ результатов экспериментов

Главная закономерность, выявленная при сравнении вариантов признаков, состоит в определяющей роли лаговых признаков продаж. Для Random Forest переход от базового набора признаков к набору `lags` снизил RMSPE с 0.2504 до 0.1461, то есть примерно на 41.6%. Лучший вариант Random Forest, `weather__holidays__lags`, дополнительно снизил RMSPE до 0.1429. Аналогичная картина наблюдается и для XGBoost: базовая модель получила RMSPE 0.1930, тогда как вариант `holidays__lags` достиг RMSPE 0.1439.

Погодные признаки без лаговых признаков не дали устойчивого улучшения качества. Для Random Forest добавление только погодных признаков практически не изменило RMSPE относительно базового варианта: 0.2504 для `base` и 0.2499 для `weather`. Более того, комбинация `weather__holidays` для Random Forest оказалась хуже базового варианта по RMSPE: 0.2560 против 0.2504. Для XGBoost погодные признаки улучшали качество относительно `base`, однако основной прирост всё равно был связан именно с добавлением лагов. Это указывает на то, что информация о погоде имеет ограниченную самостоятельную предсказательную силу в рассматриваемой задаче.

Признак Google Trends также не показал устойчивого положительного эффекта. Например, для Random Forest варианты `weather` и `weather__google_trends` дали практически одинаковые значения RMSPE, а для XGBoost добавление Google Trends к погодным признакам ухудшило RMSPE с 0.1714 до 0.1743. Возможное объяснение состоит в том, что агрегированный поисковый интерес слабо связан с ежедневными продажами конкретных магазинов или уже частично отражается через календарные и исторические признаки.

Отдельно следует отметить, что XGBoost не превзошёл Random Forest, хотя в задачах табличного машинного обучения градиентный бустинг часто оказывается одним из сильнейших методов. В рамках данного исследования это может объясняться фиксированными гиперпараметрами, отсутствием полного подбора параметров, а также сильной ролью лаговых и календарных признаков, которые Random Forest эффективно использует за счёт усреднения большого числа деревьев. При этом разница между лучшими моделями мала, поэтому результат следует интерпретировать как преимущество Random Forest именно в рамках заданных условий эксперимента, а не как универсальное превосходство метода.

Линейная регрессия показала заметно худшее качество по сравнению с древесными ансамблями: лучший вариант Linear Regression получил RMSPE 0.2026, тогда как лучшие Random Forest и XGBoost находились около 0.143. Это указывает на наличие нелинейных зависимостей между признаками и продажами, например различных эффектов промо-акций в зависимости от дня недели, типа магазина и календарного периода.

### 5.2. Интерпретация основных результатов

Основным результатом работы является эмпирическая оценка вклада различных групп признаков в качество прогнозирования дневных продаж магазинов Rossmann. В отличие от простого сравнения нескольких моделей, в исследовании проведён систематический перебор 48 вариантов набора признаков для трёх классов моделей: Linear Regression, Random Forest и XGBoost.

Основные результаты исследования можно сформулировать следующим образом:

- установлено, что наибольший вклад в качество прогнозирования дают лаговые признаки продаж, отражающие краткосрочную инерционность спроса;
- показано, что внешние признаки без лаговых признаков дают ограниченный прирост

качества и в ряде случаев не улучшают прогноз относительно базовых вариантов;

- выявлено, что лучший результат по RMSPE был получен для Random Forest с набором признаков `weather__holidays__lags`;
- показано, что XGBoost даёт близкое качество к Random Forest, однако в проведённом переборе Random Forest чаще занимал верхние позиции;
- установлено, что использование максимального количества признаков не гарантирует наилучшего качества прогноза: более компактные наборы с лаговыми и праздничными признаками оказались эффективнее некоторых расширенных наборов.

Отдельный интерес представляет ограниченный вклад погодных признаков и макроэкономического признака по сравнению с лаговыми, промо- и календарными признаками.

### 5.3. Практическая значимость

Полученные результаты имеют практическое значение для задач операционного планирования в розничной торговле. Более точный прогноз дневных продаж может использоваться для планирования товарных запасов, снижения риска дефицита товаров, оптимизации поставок и распределения персонала между магазинами. Кроме того, оценка важности признаков показывает, какие источники данных целесообразно учитывать в первую очередь при построении прикладной модели прогнозирования.

С практической точки зрения наиболее полезным результатом является вывод о высокой модельной важности истории продаж, промо-акций и календарных признаков. Это означает, что при ограниченных ресурсах на сбор внешних данных приоритет следует отдавать корректному формированию лаговых и календарных признаков, учёту промо-активности и качественной валидации модели. Внешние источники, такие как погода, Google Trends и макроэкономический показатель уровня безработицы, следует добавлять только после проверки их фактического вклада на валидационной выборке.

### 5.4. Ограничения исследования

Проведённое исследование имеет ряд ограничений, которые необходимо учитывать при интерпретации результатов.

- Использовался один набор данных Rossmann Store Sales, поэтому выводы могут зависеть от специфики данной торговой сети и рассматриваемого периода.
- Для оценки качества применялось одно временное разбиение на обучающую и валидационную выборки. Более строгая проверка могла бы включать последовательную временную валидацию или `TimeSeriesSplit`.
- Статистическая значимость различий между моделями не проверялась отдельно; выводы основаны на сравнении значений метрик на выбранной валидационной выборке.
- Внешние признаки были агрегированы на уровне даты и региона, что могло сгладить локальные эффекты погоды и поискового интереса; макроэкономический показатель уровня безработицы использовался на месячном уровне.
- В работе не моделировались возможные задержки публикации внешних данных. В прикладной системе прогнозирования необходимо дополнительно проверять, были ли соответствующие значения доступны на момент построения прогноза.



- Полный подбор гиперпараметров не проводился: параметры моделей были зафиксированы для обеспечения сопоставимости экспериментов.
- В работе не рассматривались CatBoost, LightGBM и нейросетевые модели временных рядов, которые могут быть исследованы в дальнейшем.
- Для линейной регрессии часть фиктивных признаков является линейно зависимой, поэтому коэффициенты этой модели использовались только для общей интерпретации групп признаков, а не как строгие независимые эффекты отдельных признаков.

## 6. Заключение

В результате проведённого исследования было установлено, что наибольший вклад в повышение качества прогнозирования дневных продаж вносят **лаговые признаки**, отражающие краткосрочную инерционность спроса. Все лучшие варианты моделей по метрике RMSPE включали группу `lags`, что подтверждает высокую предсказательную полезность исторической информации о продажах.

Наилучший результат был получен для модели Random Forest с набором признаков `weather__holidays__lags`. Значение RMSPE составило 0.1429, MAE — 683 EUR, а коэффициент детерминации  $R^2$  — 0.8986. Данный вариант обеспечил минимальную относительную ошибку среди всех протестированных комбинаций признаков.

Исследовательская гипотеза подтвердилась частично: добавление внешних признаков не во всех случаях приводило к улучшению качества модели. Погодные данные, Google Trends и макроэкономический показатель уровня безработицы без лаговых признаков демонстрировали ограниченную самостоятельную предсказательную силу. Основной вклад в снижение ошибки был связан не с внешними источниками данных, а с лаговыми признаками продаж. Это указывает на необходимость эмпирической проверки вклада внешних источников данных на валидационной выборке перед их включением в модель.

Кроме того, результаты показали, что максимальное расширение набора признаков не гарантирует повышения качества прогнозирования. Более компактные наборы признаков, включающие лаги, праздничные и погодные признаки, оказались эффективнее некоторых расширенных комбинаций.

Таким образом, для дальнейшего использования в рамках данной задачи целесообразно выбрать модель Random Forest с набором признаков `weather__holidays__lags`. Модели XGBoost также показали близкое качество, однако в условиях проведённого эксперимента немного уступили лучшему варианту Random Forest по основной метрике RMSPE.

## 7. Список литературы

- [1] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [3] Hyunyoung Choi and Hal Varian. Predicting the present with google trends. *The Economic Record*, 88(s1):2–9, 2012.



- [4] Federal Reserve Bank of St. Louis. Harmonized unemployment rate: All persons for germany. <https://fred.stlouisfed.org/series/LRHUTTTTDEM156S>. Accessed: 2026-05-15.
- [5] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [6] Google. Google trends. <https://trends.google.com/>. Accessed: 2026-05-15.
- [7] Kaggle and Rossmann. Rossmann store sales. <https://www.kaggle.com/c/rossmann-store-sales>, 2015. Accessed: 2026-05-15.
- [8] Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4):1346–1364, 2022.
- [9] Open-Meteo. Historical weather api. <https://open-meteo.com/en/docs/historical-weather-api>. Accessed: 2026-05-15.
- [10] Natalie Rose and Les Dolega. It’s the weather: Quantifying the impact of weather on retail sales. *Applied Spatial Analysis and Policy*, 15(1):189–214, 2022.