

Прикладные задачи анализа данных

Анализ вклада внешних и исторических признаков в качество
прогнозирования спроса в розничной сети

Медведев Максим Юрьевич, Радько Роман Олегович — БПМ255

15 мая 2026 г.

Содержание

1	Введение	2
1.1	Постановка задачи	2
1.2	Исходные данные	2
2	Обзор литературы	4
3	Методы исследования	4
3.1	Общая схема исследования	4
3.2	Организация проекта и воспроизводимость экспериментов	5
3.3	Постановка экспериментов	7
3.3.1	Формирование лаговых признаков и контроль утечки данных	8
3.4	Метрики качества	8
3.5	Гиперпараметры моделей	9
4	Результаты	10
4.1	Сравнение моделей и вариантов признаков	10
4.1.1	Наивные базовые модели	12
4.1.2	Лучшие модели	12
4.2	Анализ важности признаков	17
5	Обсуждение	21
5.1	Анализ результатов экспериментов	22
5.2	Интерпретация основных результатов	22
5.3	Практическая значимость	23
5.4	Ограничения исследования	23
6	Заключение	24
7	Список литературы	24

1. Введение

1.1. Постановка задачи

Актуальность исследования обусловлена необходимостью повышения точности прогнозирования спроса в розничной торговле. Ошибки прогноза дневных продаж могут приводить к избыточным запасам, дефициту товаров и снижению эффективности операционного планирования.

Объектом исследования являются дневные продажи магазинов сети Rossmann. Предметом исследования выступает вклад внутренних, исторических и внешних признаков в качество прогнозирования продаж.

Целью работы является оценка вклада дополнительных групп признаков в качество прогнозирования дневных продаж магазинов по сравнению с моделями, использующими базовый набор признаков датасета Rossmann Store Sales.

Для достижения поставленной цели решаются следующие задачи:

- подготовить исходные данные и объединить их со справочной информацией о магазинах;
- сформировать базовый набор признаков, исторические признаки продаж и дополнительные внешние признаки;
- построить модели для различных наборов признаков;
- сравнить качество моделей с использованием метрик;
- определить группы признаков, вносящие наибольший вклад в качество прогнозирования.

Исследовательская гипотеза состоит в том, что добавление внешних признаков может улучшить качество прогнозирования по сравнению с базовой моделью. Дополнительно проверяется, какие группы признаков дают наибольший вклад в снижение ошибки прогноза.

Сравнение моделей проводится на основе временного разбиения данных. Модель обучается на более раннем временном интервале, а её качество оценивается на более позднем периоде. Такой подход позволяет приблизить эксперимент к реальной задаче прогнозирования будущих продаж.

1.2. Исходные данные

В качестве исходных данных используется готовый набор Rossmann Store Sales, содержащий историческую информацию о продажах в 1115 магазинах немецкой сети drogери [7].

Представленные в датасете признаки можно классифицировать по типу данных следующим образом:

- числовые;
- категориальные;
- бинарные;
- временные.

Таблица для обучения (`train.csv`) содержит следующие признаки:

- **Store** — идентификатор магазина;
- **DayOfWeek** — день недели (временной признак);
- **Date** — дата (временной признак);
- **Sales** — дневная выручка (числовой признак), являющаяся целевой переменной задачи прогнозирования;
- **Customers** — число покупателей (числовой признак);
- **Open** — был ли магазин открыт (бинарный признак);
- **Promo** — была ли в этот день акция (бинарный признак);
- **StateHoliday** — тип государственного праздника или его отсутствие (категориальный признак);
- **SchoolHoliday** — школьные каникулы (бинарный признак).

Признак **Customers** не использовался при обучении моделей, поскольку в реальной задаче прогнозирования будущих продаж количество покупателей заранее неизвестно. Использование этого признака могло бы привести к утечке информации, то есть к ситуации, когда модель получает данные, которые в реальной задаче заранее были бы неизвестны.

`test.csv` — файл, содержащий наблюдения, для которых необходимо спрогнозировать значения целевой переменной **Sales**. В настоящем исследовании данный файл не использовался, поскольку в нём отсутствуют фактические значения **Sales**. Оценка качества моделей проводилась на валидационной выборке, сформированной путём временного разделения данных из `train.csv`.

Таблица `store.csv` содержит справочную информацию по магазинам:

- **Store** — идентификатор магазина;
- **StoreType** — тип магазина (категориальный признак);
- **Assortment** — тип ассортимента (категориальный признак);
- **CompetitionDistance** — расстояние до ближайшего конкурента (числовой признак);
- **CompetitionOpenSinceMonth** — месяц, когда ближайший конкурент начал работать (временной признак);
- **CompetitionOpenSinceYear** — год, когда ближайший конкурент начал работать (временной признак);
- **Promo2** — участвует ли магазин в длительной повторяющейся промо-кампании (бинарный признак);
- **Promo2SinceWeek** — неделя, с которой началась **Promo2** (временной признак);
- **Promo2SinceYear** — год начала **Promo2** (временной признак);
- **PromoInterval** — месяцы проведения длительной промо-кампании **Promo2** (категориальный признак).

Также использовалась таблица `store_states.csv`, содержащая соответствие магазинов федеральным землям Германии. Она применялась для объединения данных о магазинах с внешними признаками, зависящими от региона.

2. Обзор литературы

Прогнозирование спроса в розничной торговле является сложной задачей, поскольку продажи зависят одновременно от календарных факторов, характеристик магазина, промо-акций, сезонности и внешней среды. В современных исследованиях и соревнованиях по прогнозированию спроса широко применяются методы машинного обучения для табличных данных, в том числе ансамбли решающих деревьев. Результаты соревнования M5 показывают, что в задачах розничного прогнозирования существенную роль играют признаки, отражающие историю спроса, календарь и промо-активность [8].

Связь погодных условий с продажами также рассматривается в прикладных исследованиях розничной торговли. Например, Н. Роуз и Л. Долега анализируют связь между погодными условиями и ежедневными продажами крупного ритейлера, используя, в том числе, методы случайного леса [10]. Такие исследования показывают, что погодные признаки потенциально могут быть полезны для прогнозирования спроса, однако величина и направление эффекта зависят от товарной категории, региона и типа магазина.

Отдельное направление связано с использованием поискового интереса как внешнего индикатора экономической активности. Х. Чой и Х. Вэриан показали, что данные Google Trends могут быть полезны для краткосрочного прогнозирования ряда экономических показателей, поскольку поисковые запросы отражают текущий интерес пользователей до публикации официальной статистики [3]. В контексте данной работы это мотивирует проверку признака *GoogleTrend*, однако его полезность для конкретной задачи прогнозирования продаж должна оцениваться эмпирически.

Таким образом, существующие исследования подтверждают целесообразность проверки внешних признаков в задачах прогнозирования спроса. При этом заранее нельзя утверждать, что каждый внешний источник данных улучшит качество модели. Его вклад зависит от временного горизонта прогноза, качества агрегации данных, типа товаров и уже имеющихся внутренних признаков.

3. Методы исследования

3.1. Общая схема исследования

После анализа структуры исходных данных задача была сформулирована как **задача регрессии**: по информации о магазине, календарной дате, промо-акциях, исторических продажах и дополнительных внешних признаках необходимо предсказать дневной объём продаж *Sales*. Поскольку данные имеют временную природу, при построении и оценке моделей важно сохранять хронологический порядок наблюдений и не перемешивать обучающую и валидационную выборки случайным образом.

В качестве основного направления решения были выбраны методы машинного обучения для табличных данных, в первую очередь ансамблевые методы на основе решающих деревьев. Такой выбор обусловлен тем, что продажи в розничной торговле могут зависеть от большого числа разнородных признаков: типа магазина, ассортимента, промо-акций, дня недели, праздников, сезонности и внешних условий. Кроме того, связь этих признаков с продажами может быть нелинейной: например, эффект промо-акции может различаться для разных типов магазинов, дней недели или периодов года.

Одним из наиболее подходящих методов для такой постановки является градиентный бустинг над решающими деревьями. Метод градиентного бустинга был формализован в

работе Дж. Фридмана, где бустинг рассматривается как последовательное построение аддитивной модели, минимизирующей функцию потерь [5]. В практической части работы использовалась реализация XGBoost, предложенная Т. Ченом и К. Гестрином [2]. Данный алгоритм хорошо подходит для задач с большим числом наблюдений и неоднородными признаками, что соответствует структуре рассматриваемого набора данных.

Также в качестве альтернативных моделей были рассмотрены линейная регрессия и случайный лес. Линейная регрессия использовалась как базовая интерпретируемая модель, позволяющая оценить качество простого линейного подхода. Метод случайного леса был систематически описан Л. Брейманом [1]; в данной работе он был выбран как ансамблевый нелинейный метод, позволяющий учитывать сложные зависимости между признаками без последовательного бустинга.

Выбор ансамблевых методов и лаговых признаков согласуется с практикой современных соревнований по прогнозированию спроса. Например, в соревновании M5, посвящённом прогнозированию розничных продаж, важную роль играли методы машинного обучения для табличных данных и признаки, описывающие историю спроса [8].

Общий ход исследования был следующим. Сначала исходные данные были очищены и объединены со справочной информацией о магазинах. Затем были сформированы дополнительные признаки: календарные признаки, фиктивные признаки для категориальных признаков, признаки праздников, погодные признаки, признак уровня безработицы, Google Trends, взаимодействия промо-акций и погоды, а также лаговые признаки продаж. Далее все признаки были разделены на несколько смысловых групп, что позволило провести серию экспериментов с различными наборами признаков.

Для оценки качества моделей исходная обучающая выборка была разделена на обучающую и валидационную части по времени. Наблюдения до 2015-06-01 использовались для обучения, а наблюдения начиная с 2015-06-01 — для валидации. Такой способ деления имитирует реальную задачу прогнозирования будущих продаж на основе исторических данных.

Качество моделей оценивалось с помощью трёх метрик: RMSPE, MAE и R^2 . Основной метрикой сравнения была выбрана RMSPE, поскольку она измеряет относительную ошибку прогноза и учитывает различия в масштабе продаж между магазинами. После сравнения моделей и вариантов признаков для лучших моделей был проведён анализ важности признаков, позволяющий определить, какие признаки были наиболее важны для формирования прогноза.

3.2. Организация проекта и воспроизводимость экспериментов

Для обеспечения воспроизводимости экспериментов проект был организован следующим образом:

```
Sem/  
|-- data/  
|   |-- raw/  
|   |-- external/  
|   '-- cache/  
|-- src/  
|   |-- data/  
|   '-- models/  
|-- outputs/
```

```
| |-- figures/  
| |-- models/  
| '-- reports/  
|-- notebooks/  
|-- requirements.txt  
'-- README.md
```

В папке `data/raw/` хранятся исходные данные Rossmann:

- `train.csv`,
- `test.csv`,
- `store.csv`,
- `store_states.csv`.

В папке `data/external/` хранятся внешние данные:

- `weather_daytime.csv`,
- `googletrend_self.csv`,
- `unemployment_germany.csv`.

Погодные данные были получены через архивный API Open-Meteo [9] для столиц федеральных земель Германии и агрегированы до дневного уровня за рабочие часы магазинов. Данные Google Trends [6] были сформированы для запроса `rossmann` по федеральным землям Германии. Показатель безработицы был получен из FRED [4] как месячный показатель *Harmonized Unemployment Rate* для Германии. Внешние данные объединялись с основным датасетом по дате и региону; для месячного показателя безработицы значение месяца распространялось на все дни соответствующего месяца.

В папке `src/models/` находятся скрипты обучения моделей:

- `common.py` — содержит общие функции подготовки данных, формирования признаков и расчёта метрик;
- `model_runtime.py` — содержит вспомогательные функции для сохранения моделей, конфигураций и метаданных экспериментов;
- `feature_variant_search.py` — перебирает варианты признаков и обучает модели на разных наборах;
- `linear_regression.py` — обучает модель линейной регрессии на выбранном наборе признаков и сохраняет результаты;
- `random_forest.py` — обучает модель случайного леса на выбранном наборе признаков и строит график важности признаков;
- `xgboost_shap.py` — обучает модель XGBoost на выбранном наборе признаков и выполняет SHAP-анализ важности признаков.

В папке `outputs/models/` сохраняются обученные модели и метаданные:

- `linear_regression.pkl`,
- `random_forest.pkl`,
- `xgboost_shap_holidays_lags.json`,

- `feature_columns.json`,
- `preprocessing_config.json`.

В папке `outputs/reports/` сохраняются результаты экспериментов:

- `feature_variant_metrics.csv`,
- `feature_variant_metrics.json`,
- `feature_importance_xgboost.csv`,
- `experiments_summary.md`.

В папке `src/data/` находятся скрипты подготовки внешних данных:

- `weather.py`,
- `google_trends_parsing.py`,
- `unemployment.py`.

Актуальная версия проекта размещена в открытом репозитории GitHub: <https://github.com/alwaysnervous/rossman>.

Репозиторий содержит исходный код предобработки данных, обучения моделей, проведения экспериментов, построения графиков, а также итоговый отчёт, результаты экспериментов и файл `requirements.txt` с используемыми зависимостями. Наличие репозитория позволяет проследить структуру проекта и воспроизвести основные этапы исследования. Бинарные файлы обученных моделей и служебные файлы окружения не включались в репозиторий, поскольку они не являются необходимыми для анализа структуры проекта и могут быть заново получены запуском соответствующих скриптов.

3.3. Постановка экспериментов

Во всех экспериментах использовался датасет Rossmann с целевой переменной `Sales`.

Из обучающей выборки были исключены строки, соответствующие дням, когда магазин был закрыт: `Open = 0`. Такие наблюдения не отражают фактический потребительский спрос, поскольку продажи в эти дни равны нулю. Поэтому в дальнейшем задача рассматривается как прогнозирование продаж для дней, когда магазин открыт. После такой фильтрации признак `Open` фактически становится константным и не используется при интерпретации результатов как содержательно информативный признак.

Разделение на обучающую и валидационную выборки выполнялось по времени:

- обучающая выборка: даты до `2015-06-01`;
- валидационная выборка: даты начиная с `2015-06-01`.

Категориальные признаки `StateHoliday`, `StoreType`, `Assortment` и `PromoInterval` кодировались методом прямого кодирования категориальных признаков (one-hot encoding). При кодировании использовался параметр `dummy_na=True`, поэтому для пропущенных значений создавался отдельный фиктивный признак.

После кодирования категориальных признаков оставшиеся пропуски в числовых признаках заполнялись нулём: `fillna(0)`. В данной работе это значение использовалось как техническое обозначение отсутствующей или неизвестной информации.

3.3.1. Формирование лаговых признаков и контроль утечки данных

Отдельное внимание было уделено лаговым признакам продаж, поскольку они используют значения целевой переменной за предыдущие моменты времени. Для каждого магазина лаговые признаки вычислялись внутри соответствующего временного ряда после сортировки наблюдений по **Store** и **Date**. Поскольку строки с закрытыми магазинами были исключены, индекс t в формулах ниже обозначает номер доступного наблюдения для конкретного магазина, а не обязательно последовательный календарный день. При расчёте использовались только значения продаж, предшествующие текущему наблюдению:

$$\text{Sales_Lag1}_{s,t} = \text{Sales}_{s,t-1},$$

$$\text{Sales_Lag7}_{s,t} = \text{Sales}_{s,t-7},$$

$$\text{Sales_Rolling7}_{s,t} = \frac{1}{m_{s,t}} \sum_{k=1}^{m_{s,t}} \text{Sales}_{s,t-k}, \quad m_{s,t} = \min(7, t-1).$$

Здесь s обозначает магазин, а t — порядковый номер доступного наблюдения для данного магазина. Таким образом, **Sales_Lag1** соответствует предыдущему доступному наблюдению, а **Sales_Lag7** — седьмому предыдущему доступному наблюдению. При формировании признаков не использовались значения продаж за текущий день и будущие наблюдения. Эксперимент соответствует постановке *one-step-ahead forecasting*: при прогнозировании очередного дня предполагается, что фактические продажи за предыдущие доступные дни уже известны. Для многодневного прогноза без обновления фактических продаж потребовалась бы отдельная рекурсивная схема расчёта лаговых признаков.

Следует также отметить, что признаки **DayOfWeek** и **dayofweek** содержательно описывают один и тот же календарный фактор. Первый признак присутствует в исходном датасете **Rossmann**, а второй был автоматически извлечён из поля **Date** средствами **pandas**. Они отличаются кодировкой: **DayOfWeek** принимает значения от 1 до 7, тогда как **dayofweek** — от 0 до 6. Поэтому при интерпретации важности признаков их следует рассматривать совместно как признаки дня недели.

3.4. Метрики качества

Для оценки качества прогнозирования использовались три метрики: RMSPE, MAE и коэффициент детерминации R^2 . Пусть y_i обозначает фактическое значение продаж, $\hat{y}_i$ — прогноз модели, $\bar{y}$ — среднее фактическое значение целевой переменной, а n — число наблюдений.

Основной метрикой сравнения была выбрана RMSPE:

$$\text{RMSPE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{y_i} \right)^2}.$$

Данная метрика измеряет относительную ошибку прогноза и поэтому подходит для сравнения магазинов с различным масштабом продаж.

При расчёте RMSPE учитывались только наблюдения с положительным фактическим значением продаж, поскольку метрика содержит деление на фактическое значение целевой переменной.

Дополнительно использовалась средняя абсолютная ошибка MAE:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

MAE показывает среднюю абсолютную ошибку прогноза в денежных единицах и является удобной для практической интерпретации.

Также рассчитывался коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Метрика R^2 показывает долю вариации целевой переменной, объясняемую моделью, и использовалась как вспомогательный показатель качества.

3.5. Гиперпараметры моделей

Для модели XGBoost использовались следующие параметры:

- `max_depth = 5`

Ограничивает максимальную глубину каждого дерева. Чем больше глубина, тем более сложные зависимости может учитывать модель, однако при слишком большом значении возрастает риск переобучения. В работе было выбрано значение `max_depth = 5`, чтобы сохранить баланс между гибкостью модели и устойчивостью на валидационной выборке.

- `learning_rate = 0.05`

Задаёт вклад каждого нового дерева в итоговый прогноз. Малое значение `learning_rate` делает обучение более плавным, но требует большего числа boosting-итераций.

- `objective = reg:squarederror`

Задаёт функцию потерь для задачи регрессии.

- `eval_metric = rmse`

Указывает, что во время обучения качество модели на обучающей и валидационной выборках отслеживалось по RMSE.

- `num_boost_round = 3000`

Задаёт максимальное число boosting-итераций, то есть максимальное количество деревьев, которые может построить модель. Это верхняя граница, а не обязательно фактическое число использованных деревьев.

- `early_stopping_rounds = 50`

Задаёт число итераций без улучшения качества на валидационной выборке, после которого обучение останавливается.

- `seed = 42`

Фиксирует генератор случайных чисел и делает результаты обучения более воспроизводимыми.

Номер лучшей итерации при использовании early stopping сохранялся в служебном JSON-файле, однако в основную таблицу результатов он не включался, так как не является метрикой качества и неприменим к Random Forest.

Для модели Random Forest использовались параметры:

- `n_estimators = 100`

Задаёт количество деревьев в ансамбле. Большее число деревьев обычно повышает устойчивость модели и снижает разброс прогнозов, но увеличивает время обучения и размер модели.

- `max_depth = 15`

Ограничивает глубину деревьев. Это контролирует сложность модели и снижает риск переобучения. В отличие от XGBoost, в Random Forest деревья обучаются независимо, а случайность задаётся bootstrap-подвыборками наблюдений и случайным выбором признаков при разбиениях.

- `random_state = 42`

Фиксирует случайность при построении леса: выбор подвыборок данных и признаков становится воспроизводимым.

- `n_jobs = -1`

Означает использование всех доступных ядер процессора для параллельного обучения деревьев. Этот параметр влияет на скорость обучения, но не является параметром качества модели.

4. Результаты

4.1. Сравнение моделей и вариантов признаков

Был выполнен систематический перебор комбинаций групп признаков для трёх моделей: Linear Regression, Random Forest и XGBoost.

Во всех экспериментах использовался базовый набор признаков (`base`), включающий используемые исходные признаки из `train.csv` и `store.csv`, а также календарные признаки и фиктивные признаки, полученные методом прямого кодирования категориальных признаков (`one-hot encoding`).

- идентификатор магазина:

`Store;`

- исходные календарные и бинарные признаки из `train.csv`:

`DayOfWeek, Open, Promo, SchoolHoliday;`

- признаки конкуренции и промо-программы из `store.csv`:

`CompetitionDistance,
CompetitionOpenSinceMonth,
CompetitionOpenSinceYear,
Promo2,
Promo2SinceWeek,
Promo2SinceYear;`

- календарные признаки, извлечённые из `Date`:

`year, month, day, dayofweek, WeekOfYear, IsMonthEnd, IsFriday;`

- фиктивные признаки для категориальных признаков:

`StateHoliday_0, StateHoliday_a,`

`StateHoliday_b, StateHoliday_c,`

`StateHoliday_nan,`

`StoreType_a, StoreType_b, StoreType_c, StoreType_d, StoreType_nan,`

`Assortment_a, Assortment_b, Assortment_c, Assortment_nan,`

`PromoInterval_Jan, Apr, Jul, Oct,`

`PromoInterval_Feb, May, Aug, Nov,`

`PromoInterval_Mar, Jun, Sept, Dec,`

`PromoInterval_nan.`

Признак `Open` указан как часть исходного набора данных, однако после исключения закрытых дней он принимает одно значение и поэтому не рассматривается как содержательно важный признак при интерпретации моделей.

Рассматриваемые дополнительные признаки можно разделить на две основные группы: исторические признаки продаж и внешние признаки. К историческим признакам относятся лаговые признаки, построенные по прошлым значениям продаж. К внешним признакам в данной работе относятся погодные данные, Google Trends, уровень безработицы и праздничные признаки, поскольку они формируются на основе источников, внешних по отношению к исходным таблицам `train.csv` и `store.csv`.

Дополнительно перебирались следующие 6 групп признаков:

- погодные признаки (`weather`):

`temperature_mean, temperature_max, precipitation_sum, sunshine_sum;`

производные погодные признаки:

`TempRange, IsRainy, IsSunny, IsHot, IsCold;`

- Google Trends (`google_trends`):

`GoogleTrend;`

- уровень безработицы (`unemployment`):

`UnemploymentRate;`

- праздники (`holidays`):

`PublicHoliday, BeforeHoliday, AfterHoliday;`

- взаимодействия промо и погоды (`promo_weather`):

`Promo_Temperature, Promo_Sunny, Promo_Rainy;`

- лаговые признаки продаж (`lags`):

`Sales_Lag1, Sales_Lag7, Sales_Rolling7.`

Теоретически это даёт $2^6 = 64$ комбинаций, однако группа взаимодействий промо и погоды вычисляется через погодные признаки. Поэтому комбинации, где `promo_weather = true`, но `weather = false`, были исключены.

Итоговое число вариантов признаков составило $64 - 2^4 = 64 - 16 = 48$. Для каждого варианта были обучены три модели: Linear Regression, Random Forest и XGBoost. Таким образом, всего было проведено $48 \times 3 = 144$ эксперимента.

Варианты признаков были отсортированы по RMSPE, так как эта метрика отражает относительную ошибку прогноза и лучше подходит для сравнения качества моделей при разных уровнях продаж.

Например, если магазин имеет средний уровень продаж в 1 000 €, то ошибка в 500 € будет более существенной, тогда как для магазина со средним уровнем продаж в 20 000 € такая же абсолютная ошибка будет иметь меньший относительный масштаб. Поэтому метрика MAE, несмотря на удобную интерпретацию в евро, не была использована в качестве основной метрики ранжирования.

Метрика R^2 также не была выбрана в качестве основного критерия, поскольку она показывает долю вариации целевой переменной, объясняемую моделью, но не измеряет напрямую относительный размер ошибки прогноза. Иными словами, R^2 сравнивает ошибку модели с общим разбросом фактических значений относительно среднего, а не оценивает ошибку относительно каждого конкретного значения продаж. Поэтому при прогнозировании продаж, где наблюдения могут существенно различаться по масштабу, R^2 использовалась только как вспомогательная метрика.

4.1.1. Наивные базовые модели

Помимо моделей машинного обучения был рассчитан простой наивный базовый прогноз, характерный для задач прогнозирования временных рядов. В качестве прогноза использовались только прошлые значения продаж того же магазина: продажи из предыдущего наблюдения и продажи из седьмого предыдущего наблюдения. Результаты приведены в таблице 1.

Таблица 1: Качество наивных базовых моделей

Модель	RMSPE	MAE	R^2
Naive Lag-1	0.3094	1364	0.5445
Naive Lag-7	0.4793	2434	0.0307

Сравнение показывает, что лучшие модели машинного обучения существенно превосходят наивные прогнозы по RMSPE. Это подтверждает, что для повышения качества прогнозирования недостаточно использовать только отдельные прошлые значения продаж: модели дополнительно учитывают календарные признаки, промо-акции, характеристики магазинов и нелинейные зависимости между признаками.

4.1.2. Лучшие модели

Для повышения наглядности результатов сначала представлены десять лучших экспериментов по метрике RMSPE. Полная таблица результатов для Random Forest и XGBoost приведена ниже, а результаты перебора Linear Regression вынесены в отдельную таблицу.

В столбце p указано количество признаков, использованных моделью после предобработки данных и кодирования категориальных признаков.

Таблица 2: Топ-10 экспериментов по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	RF	weather__holidays__lags	51	0.1429	683	0.8986
2	RF	weather__google_trends__holidays__lags	52	0.1432	683	0.8983
3	RF	holidays__lags	42	0.1433	687	0.8970
4	RF	google_trends__holidays__lags	43	0.1435	687	0.8969
5	RF	weather__unemployment__holidays__lags	52	0.1436	687	0.8974
6	RF	weather__google_trends__unemployment__holidays__lags	53	0.1438	687	0.8975
7	RF	unemployment__holidays__lags	43	0.1438	690	0.8969
8	RF	weather__google_trends__holidays__promo_weather__lags	55	0.1439	683	0.8983
9	XGB	holidays__lags	42	0.1439	698	0.8988
10	RF	weather__holidays__promo_weather__lags	54	0.1440	684	0.8981

Различия между лучшими моделями Random Forest и XGBoost оказались небольшими по абсолютной величине RMSPE: лучший Random Forest получил RMSPE 0.1429, а лучший XGBoost — 0.1439. В рамках выбранного временного разбиения, фиксированных гиперпараметров и рассмотренных наборов признаков Random Forest чаще занимал верхние позиции в ранжировании вариантов признаков.

Таблица 3: Ранжирование вариантов признаков по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	RF	weather__holidays__lags	51	0.1429	683	0.8986
2	RF	weather__google_trends__holidays__lags	52	0.1432	683	0.8983
3	RF	holidays__lags	42	0.1433	687	0.8970
4	RF	google_trends__holidays__lags	43	0.1435	687	0.8969
5	RF	weather__unemployment__holidays__lags	52	0.1436	687	0.8974
6	RF	weather__google_trends__unemployment__holidays__lags	53	0.1438	687	0.8975
7	RF	unemployment__holidays__lags	43	0.1438	690	0.8969
8	RF	weather__google_trends__holidays__promo_weather__lags	55	0.1439	683	0.8983
9	XGB	holidays__lags	42	0.1439	698	0.8988
10	RF	weather__holidays__promo_weather__lags	54	0.1440	684	0.8981
11	RF	google_trends__unemployment__holidays__lags	44	0.1440	690	0.8969
12	XGB	lags	39	0.1445	684	0.9024
13	RF	weather__lags	48	0.1445	693	0.8964
14	RF	weather__unemployment__holidays__promo_weather__lags	55	0.1446	687	0.8971
15	RF	weather__google_trends__lags	49	0.1446	693	0.8964
16	RF	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.1447	687	0.8972
17	RF	weather__google_trends__promo_weather__lags	52	0.1454	694	0.8961
18	RF	weather__promo_weather__lags	51	0.1456	693	0.8960
19	RF	weather__unemployment__lags	49	0.1459	699	0.8948
20	RF	weather__google_trends__unemployment__lags	50	0.1460	699	0.8949
21	RF	lags	39	0.1461	703	0.8934
22	RF	google_trends__lags	40	0.1462	703	0.8936
23	RF	weather__unemployment__promo_weather__lags	52	0.1468	699	0.8945
24	RF	weather__google_trends__unemployment__promo_weather__lags	53	0.1470	699	0.8945
25	XGB	google_trends__lags	40	0.1470	705	0.8976
26	RF	unemployment__lags	40	0.1472	708	0.8926
27	RF	google_trends__unemployment__lags	41	0.1474	708	0.8925
28	XGB	weather__unemployment__lags	49	0.1475	722	0.8896
29	XGB	weather__google_trends__lags	49	0.1481	728	0.8887
30	XGB	google_trends__holidays__lags	43	0.1488	733	0.8892
31	XGB	google_trends__unemployment__lags	41	0.1490	716	0.8944
32	XGB	weather__promo_weather__lags	51	0.1502	727	0.8890
33	XGB	weather__google_trends__unemployment__promo_weather__lags	53	0.1507	724	0.8897
34	XGB	weather__unemployment__holidays__lags	52	0.1507	749	0.8814
35	XGB	google_trends__unemployment__holidays__lags	44	0.1513	744	0.8849
36	XGB	unemployment__holidays__lags	43	0.1514	738	0.8865
37	XGB	weather__holidays__lags	51	0.1519	738	0.8842
38	XGB	weather__lags	48	0.1520	743	0.8837
39	XGB	weather__google_trends__holidays__lags	52	0.1524	734	0.8851
40	XGB	weather__google_trends__unemployment__lags	50	0.1525	740	0.8844

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
41	XGB	weather__unemployment__holidays__promo_weather__lags	55	0.1526	747	0.8810
42	XGB	weather__google_trends__unemployment__holidays__lags	53	0.1527	743	0.8829
43	XGB	unemployment__lags	40	0.1531	734	0.8877
44	XGB	weather__google_trends__promo_weather__lags	52	0.1536	738	0.8849
45	XGB	weather__google_trends__holidays__promo_weather__lags	55	0.1538	755	0.8801
46	XGB	weather__holidays__promo_weather__lags	54	0.1539	753	0.8812
47	XGB	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.1546	752	0.8800
48	XGB	unemployment__holidays	40	0.1569	724	0.8941
49	XGB	weather__unemployment__promo_weather__lags	52	0.1576	753	0.8808
50	XGB	holidays	39	0.1581	729	0.8904
51	XGB	google_trends__unemployment__holidays	41	0.1588	726	0.8934
52	XGB	google_trends__holidays	40	0.1597	731	0.8920
53	XGB	weather__holidays__promo_weather	51	0.1618	745	0.8846
54	XGB	weather__google_trends__unemployment__holidays	50	0.1652	758	0.8813
55	XGB	weather__holidays	48	0.1669	766	0.8749
56	XGB	weather__google_trends__holidays	49	0.1685	771	0.8730
57	XGB	weather__unemployment__holidays__promo_weather	52	0.1692	769	0.8736
58	XGB	weather	45	0.1714	775	0.8807
59	XGB	weather__google_trends__unemployment__holidays__promo_weather	53	0.1738	775	0.8689
60	XGB	weather__google_trends	46	0.1743	789	0.8763
61	XGB	weather__google_trends__promo_weather	49	0.1750	794	0.8768
62	XGB	weather__google_trends__holidays__promo_weather	52	0.1757	786	0.8622
63	XGB	weather__unemployment__promo_weather	49	0.1776	796	0.8757
64	XGB	weather__google_trends__unemployment	47	0.1790	788	0.8779
65	XGB	weather__unemployment	46	0.1793	800	0.8759
66	XGB	weather__google_trends__unemployment__promo_weather	50	0.1860	819	0.8687
67	XGB	base	36	0.1930	832	0.8666
68	XGB	weather__unemployment__holidays	49	0.1940	861	0.8474
69	XGB	unemployment	37	0.1947	833	0.8686
70	XGB	google_trends__unemployment	38	0.1975	835	0.8676
71	XGB	google_trends	37	0.2017	858	0.8580
72	XGB	weather__promo_weather	48	0.2025	879	0.8506
73	RF	weather	45	0.2499	1153	0.7170
74	RF	weather__promo_weather	48	0.2499	1153	0.7170
75	RF	weather__google_trends	46	0.2499	1153	0.7170
76	RF	weather__google_trends__promo_weather	49	0.2500	1153	0.7169
77	RF	base	36	0.2504	1145	0.7223
78	RF	google_trends	37	0.2505	1145	0.7222
79	RF	holidays	39	0.2558	1175	0.7097
80	RF	google_trends__holidays	40	0.2559	1176	0.7094

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
81	RF	weather__google_trends__holidays__promo_weather	52	0.2559	1184	0.7054
82	RF	weather__holidays	48	0.2560	1184	0.7055
83	RF	weather__holidays__promo_weather	51	0.2560	1184	0.7054
84	RF	weather__google_trends__holidays	49	0.2560	1184	0.7053
85	RF	google_trends__unemployment__holidays	41	0.2564	1175	0.7100
86	RF	unemployment__holidays	40	0.2564	1175	0.7099
87	RF	weather__unemployment__holidays__promo_weather	52	0.2564	1182	0.7062
88	RF	weather__unemployment__holidays	49	0.2564	1182	0.7061
89	RF	weather__google_trends__unemployment__holidays	50	0.2564	1182	0.7061
90	RF	weather__google_trends__unemployment__holidays__promo_weather	53	0.2564	1182	0.7061
91	RF	unemployment	37	0.2644	1161	0.7169
92	RF	google_trends__unemployment	38	0.2645	1161	0.7172
93	RF	weather__unemployment	46	0.2646	1169	0.7120
94	RF	weather__google_trends__unemployment__promo_weather	50	0.2646	1169	0.7119
95	RF	weather__unemployment__promo_weather	49	0.2646	1169	0.7118
96	RF	weather__google_trends__unemployment	47	0.2647	1170	0.7117

Таблица 4: Ранжирование вариантов признаков Linear Regression по RMSPE

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
1	LR	weather__unemployment__holidays__lags	52	0.2026	1012	0.7657
2	LR	weather__holidays__lags	51	0.2029	1012	0.7662
3	LR	weather__unemployment__holidays__promo_weather__lags	55	0.2034	1016	0.7643
4	LR	weather__holidays__promo_weather__lags	54	0.2038	1016	0.7648
5	LR	weather__unemployment__lags	49	0.2040	1010	0.7664
6	LR	weather__lags	48	0.2041	1010	0.7665
7	LR	weather__unemployment__promo_weather__lags	52	0.2048	1013	0.7652
8	LR	weather__promo_weather__lags	51	0.2049	1013	0.7653
9	LR	weather__google_trends__unemployment__holidays__lags	53	0.2074	1013	0.7668
10	LR	weather__google_trends__holidays__lags	52	0.2077	1012	0.7673
11	LR	weather__google_trends__unemployment__holidays__promo_weather__lags	56	0.2082	1016	0.7655
12	LR	weather__google_trends__holidays__promo_weather__lags	55	0.2085	1016	0.7660
13	LR	weather__google_trends__unemployment__lags	50	0.2087	1010	0.7676
14	LR	weather__google_trends__lags	49	0.2088	1010	0.7677
15	LR	weather__google_trends__unemployment__promo_weather__lags	53	0.2094	1013	0.7664
16	LR	weather__google_trends__promo_weather__lags	52	0.2095	1013	0.7665
17	LR	unemployment__holidays__lags	43	0.2124	1030	0.7658

Ранг	Модель	Набор признаков	p	RMSPE	MAE	R^2
18	LR	holidays__lags	42	0.2136	1032	0.7659
19	LR	unemployment__lags	40	0.2153	1033	0.7651
20	LR	lags	39	0.2160	1034	0.7651
21	LR	google_trends__unemployment__holidays__lags	44	0.2166	1029	0.7671
22	LR	google_trends__holidays__lags	43	0.2178	1031	0.7672
23	LR	google_trends__unemployment__lags	41	0.2195	1032	0.7664
24	LR	google_trends__lags	40	0.2202	1034	0.7664
25	LR	weather__holidays	48	0.4302	1914	0.2714
26	LR	weather__google_trends__holidays	49	0.4312	1914	0.2719
27	LR	weather__holidays__promo_weather	51	0.4319	1916	0.2700
28	LR	weather__google_trends__holidays__promo_weather	52	0.4328	1916	0.2705
29	LR	weather	45	0.4384	1923	0.2717
30	LR	weather__google_trends	46	0.4393	1923	0.2722
31	LR	weather__unemployment__holidays	49	0.4393	1925	0.2716
32	LR	weather__promo_weather	48	0.4400	1925	0.2704
33	LR	weather__google_trends__unemployment__holidays	50	0.4403	1925	0.2721
34	LR	weather__google_trends__promo_weather	49	0.4408	1925	0.2709
35	LR	weather__unemployment__holidays__promo_weather	52	0.4412	1928	0.2703
36	LR	weather__google_trends__unemployment__holidays__promo_weather	53	0.4422	1928	0.2708
37	LR	weather__unemployment	46	0.4499	1939	0.2702
38	LR	weather__google_trends__unemployment	47	0.4509	1940	0.2706
39	LR	weather__unemployment__promo_weather	49	0.4517	1942	0.2689
40	LR	weather__google_trends__unemployment__promo_weather	50	0.4526	1942	0.2694
41	LR	holidays	39	0.4617	1952	0.2706
42	LR	google_trends__holidays	40	0.4625	1952	0.2711
43	LR	unemployment__holidays	40	0.4713	1969	0.2666
44	LR	base	36	0.4717	1968	0.2672
45	LR	google_trends__unemployment__holidays	41	0.4722	1969	0.2671
46	LR	google_trends	37	0.4726	1968	0.2677
47	LR	unemployment	37	0.4842	1993	0.2603
48	LR	google_trends__unemployment	38	0.4850	1993	0.2607

4.2. Анализ важности признаков

Для выявления признаков с наибольшей модельной важностью был проведён анализ важности признаков. В качестве объектов анализа были выбраны модели, показавшие наилучшее качество прогнозирования на валидационной выборке (по метрике RMSPE) в рамках соответствующего класса моделей: линейной регрессии, случайного леса и XGBoost.




Рис. 1: Топ-15 важных признаков Linear Regression

Для линейной регрессии анализ проводился на основе модулей коэффициентов модели, то есть величин $|b_j|$. Наибольшие по модулю коэффициенты соответствуют признакам, связанным с промо-активностью: `PromoInterval_nan`, `Promo2`, `Promo`, а также фиктивным признакам, кодирующим месячные интервалы участия магазина в промо-кампаниях `Promo2`. Кроме того, в число признаков с наибольшими по модулю коэффициентами вошли праздничные и календарные признаки: `AfterHoliday`, `BeforeHoliday`, `StateHoliday_a`, `StateHoliday_c`, `IsMonthEnd`, `IsFriday`. Эти признаки наиболее активно используются линейной моделью при формировании прогноза.

Следует отметить, что интерпретация коэффициентов линейной регрессии имеет ряд ограничений. Абсолютная величина коэффициента зависит от масштаба соответствующего признака, а также от наличия корреляции между признаками. Например, `Promo2` и `PromoInterval_nan` содержательно связаны между собой, поэтому высокие значения их коэффициентов не следует трактовать как полностью независимый вклад каждого признака в прогноз целевой переменной. Тем не менее анализ коэффициентов позволяет выявить группы признаков, наиболее активно используемые линейной моделью.




Рис. 2: Топ-15 важных признаков Random Forest

Для модели Random Forest важность признаков оценивалась на основе встроенной меры важности, рассчитываемой по уменьшению ошибки в деревьях ансамбля. Все важности в Random Forest нормируются так, что сумма важностей всех признаков равна 1. Наиболее важным для модели признаком оказался **Sales_Lag1**, отражающий объём продаж в предыдущем доступном наблюдении для данного магазина. Его вклад существенно превышает вклад остальных признаков, что свидетельствует о сильной связи прогноза текущего наблюдения с уровнем продаж в предыдущем доступном наблюдении.

Следующими по модельной важности для Random Forest являются сглаженная история продаж за предыдущие наблюдения, промо-акция, признаки дня недели, календарные признаки и недельный лаг продаж. Это показывает, что модель использует как краткосрочную историю продаж, так и регулярные календарные закономерности. Наличие промо-акции также входит в число ключевых факторов, что согласуется с экономической логикой задачи прогнозирования розничных продаж.




Рис. 3: Средняя абсолютная важность признаков XGBoost по SHAP

Для модели XGBoost был применён SHAP-анализ, позволяющий оценить вклад каждого признака в индивидуальные прогнозы модели. В отличие от обычной важности признаков, SHAP-значения позволяют рассматривать не только среднюю силу вклада признака, но и **направление этого вклада**. Согласно графику средней абсолютной важности, наибольший вклад в прогноз XGBoost вносят признаки **Sales_Rolling7**, **Promo**, **Sales_Lag1**, **DayOfWeek**, **day**, **IsFriday**, **WeekOfYear** и **Sales_Lag7**. Таким образом, XGBoost, как и Random Forest, в первую очередь использует информацию о продажах за предыдущие доступные наблюдения, промо-активности и календарных закономерностях.




Рис. 4: Направление вклада признаков в прогноз XGBoost

Summary-график SHAP дополнительно показывает характер вклада признаков в прогноз. Высокие значения `Sales_Rolling7`, `Sales_Lag1` и `Sales_Lag7`, как правило, смещают прогноз продаж вверх, что подтверждает наличие инерционности продаж. Признак `Promo` также преимущественно даёт положительный вклад в прогноз, поскольку проведение промо-акций связано с ростом ожидаемых продаж. Для признака `DayOfWeek` наблюдается более сложная структура вклада: различные значения дня недели могут как увеличивать, так и уменьшать прогноз, что отражает недельную сезонность покупательского поведения.

Сопоставление результатов для трёх моделей показывает, что наиболее информативными являются три группы признаков: лаговые признаки продаж, признаки промо-акций и календарные признаки. Данные группы признаков имеют высокую модельную важность как для линейной модели, так и для ансамблевых древесных алгоритмов. Внешние признаки, такие как погодные показатели и уровень безработицы, не вошли в число наиболее важных признаков для лучших древесных моделей. Это свидетельствует о том, что в рассматриваемой задаче их вклад в качество прогнозирования оказался ниже по сравнению с историей продаж, промо-акциями и календарными закономерностями.

5. Обсуждение

5.1. Анализ результатов экспериментов

Главная закономерность, выявленная при сравнении вариантов признаков, состоит в определяющей роли лаговых признаков продаж. Для Random Forest переход от базового набора признаков к набору `lags` снизил RMSPE с 0.2504 до 0.1461, то есть примерно на 41.6%. Лучший вариант Random Forest, `weather__holidays__lags`, дополнительно снизил RMSPE до 0.1429. Аналогичная картина наблюдается и для XGBoost: базовая модель получила RMSPE 0.1930, тогда как вариант `holidays__lags` достиг RMSPE 0.1439.

Погодные признаки без лаговых признаков не дали устойчивого улучшения качества. Для Random Forest добавление только погодных признаков практически не изменило RMSPE относительно базового варианта: 0.2504 для `base` и 0.2499 для `weather`. Более того, комбинация `weather__holidays` для Random Forest оказалась хуже базового варианта по RMSPE: 0.2560 против 0.2504. Для XGBoost погодные признаки улучшали качество относительно `base`, однако основной прирост всё равно был связан именно с добавлением лагов. Это указывает на то, что информация о погоде имеет ограниченную самостоятельную предсказательную силу в рассматриваемой задаче.

Признак Google Trends также не показал устойчивого положительного эффекта. Например, для Random Forest варианты `weather` и `weather__google_trends` дали практически одинаковые значения RMSPE, а для XGBoost добавление Google Trends к погодным признакам ухудшило RMSPE с 0.1714 до 0.1743. Возможное объяснение состоит в том, что агрегированный поисковый интерес слабо связан с ежедневными продажами конкретных магазинов или уже частично отражается через календарные и исторические признаки.

Отдельно следует отметить, что XGBoost не превзошёл Random Forest, хотя в задачах табличного машинного обучения градиентный бустинг часто оказывается одним из сильнейших методов. В рамках данного исследования это может объясняться фиксированными гиперпараметрами, отсутствием полного подбора параметров, а также сильной ролью лаговых и календарных признаков, которые Random Forest эффективно использует за счёт усреднения большого числа деревьев. При этом разница между лучшими моделями мала, поэтому результат следует интерпретировать как преимущество Random Forest именно в рамках заданных условий эксперимента, а не как универсальное превосходство метода.

Линейная регрессия показала заметно худшее качество по сравнению с древесными ансамблями: лучший вариант Linear Regression получил RMSPE 0.2026, тогда как лучшие Random Forest и XGBoost находились около 0.143. Это указывает на наличие нелинейных зависимостей между признаками и продажами, например различных эффектов промо-акций в зависимости от дня недели, типа магазина и календарного периода.

5.2. Интерпретация основных результатов

Основным результатом работы является эмпирическая оценка вклада различных групп признаков в качество прогнозирования дневных продаж магазинов Rossmann. В отличие от простого сравнения нескольких моделей, в исследовании проведён систематический перебор 48 вариантов набора признаков для трёх классов моделей: Linear Regression, Random Forest и XGBoost.

Основные результаты исследования можно сформулировать следующим образом:

- установлено, что наибольший вклад в качество прогнозирования дают лаговые признаки продаж, отражающие краткосрочную инерционность спроса;
- показано, что внешние признаки без лаговых признаков дают ограниченный прирост

качества и в ряде случаев не улучшают прогноз относительно базовых вариантов;

- выявлено, что лучший результат по RMSPE был получен для Random Forest с набором признаков `weather__holidays__lags`;
- показано, что XGBoost даёт близкое качество к Random Forest, однако в проведённом переборе Random Forest чаще занимал верхние позиции;
- установлено, что использование максимального количества признаков не гарантирует наилучшего качества прогноза: более компактные наборы с лаговыми и праздничными признаками оказались эффективнее некоторых расширенных наборов.

Отдельный интерес представляет ограниченный вклад погодных признаков и макроэкономического признака по сравнению с лаговыми, промо- и календарными признаками.

5.3. Практическая значимость

Полученные результаты имеют практическое значение для задач операционного планирования в розничной торговле. Более точный прогноз дневных продаж может использоваться для планирования товарных запасов, снижения риска дефицита товаров, оптимизации поставок и распределения персонала между магазинами. Кроме того, оценка важности признаков показывает, какие источники данных целесообразно учитывать в первую очередь при построении прикладной модели прогнозирования.

С практической точки зрения наиболее полезным результатом является вывод о высокой модельной важности истории продаж, промо-акций и календарных признаков. Это означает, что при ограниченных ресурсах на сбор внешних данных приоритет следует отдавать корректному формированию лаговых и календарных признаков, учёту промо-активности и качественной валидации модели. Внешние источники, такие как погода, Google Trends и макроэкономический показатель уровня безработицы, следует добавлять только после проверки их фактического вклада на валидационной выборке.

5.4. Ограничения исследования

Проведённое исследование имеет ряд ограничений, которые необходимо учитывать при интерпретации результатов.

- Использовался один набор данных Rossmann Store Sales, поэтому выводы могут зависеть от специфики данной торговой сети и рассматриваемого периода.
- Для оценки качества применялось одно временное разбиение на обучающую и валидационную выборки. Более строгая проверка могла бы включать последовательную временную валидацию или `TimeSeriesSplit`.
- Статистическая значимость различий между моделями не проверялась отдельно; выводы основаны на сравнении значений метрик на выбранной валидационной выборке.
- Внешние признаки были агрегированы на уровне даты и региона, что могло сгладить локальные эффекты погоды и поискового интереса; макроэкономический показатель уровня безработицы использовался на месячном уровне.
- В работе не моделировались возможные задержки публикации внешних данных. В прикладной системе прогнозирования необходимо дополнительно проверять, были ли соответствующие значения доступны на момент построения прогноза.

- Полный подбор гиперпараметров не проводился: параметры моделей были зафиксированы для обеспечения сопоставимости экспериментов.
- В работе не рассматривались CatBoost, LightGBM и нейросетевые модели временных рядов, которые могут быть исследованы в дальнейшем.
- Для линейной регрессии часть фиктивных признаков является линейно зависимой, поэтому коэффициенты этой модели использовались только для общей интерпретации групп признаков, а не как строгие независимые эффекты отдельных признаков.

6. Заключение

В результате проведённого исследования было установлено, что наибольший вклад в повышение качества прогнозирования дневных продаж вносят **лаговые признаки**, отражающие краткосрочную инерционность спроса. Все лучшие варианты моделей по метрике RMSPE включали группу `lags`, что подтверждает высокую предсказательную полезность исторической информации о продажах.

Наилучший результат был получен для модели Random Forest с набором признаков `weather__holidays__lags`. Значение RMSPE составило 0.1429, MAE — 683 EUR, а коэффициент детерминации R^2 — 0.8986. Данный вариант обеспечил минимальную относительную ошибку среди всех протестированных комбинаций признаков.

Исследовательская гипотеза подтвердилась частично: добавление внешних признаков не во всех случаях приводило к улучшению качества модели. Погодные данные, Google Trends и макроэкономический показатель уровня безработицы без лаговых признаков демонстрировали ограниченную самостоятельную предсказательную силу. Основной вклад в снижение ошибки был связан не с внешними источниками данных, а с лаговыми признаками продаж. Это указывает на необходимость эмпирической проверки вклада внешних источников данных на валидационной выборке перед их включением в модель.

Кроме того, результаты показали, что максимальное расширение набора признаков не гарантирует повышения качества прогнозирования. Более компактные наборы признаков, включающие лаги, праздничные и погодные признаки, оказались эффективнее некоторых расширенных комбинаций.

Таким образом, для дальнейшего использования в рамках данной задачи целесообразно выбрать модель Random Forest с набором признаков `weather__holidays__lags`. Модели XGBoost также показали близкое качество, однако в условиях проведённого эксперимента немного уступили лучшему варианту Random Forest по основной метрике RMSPE.

7. Список литературы

- [1] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [3] Hyunyoung Choi and Hal Varian. Predicting the present with google trends. *The Economic Record*, 88(s1):2–9, 2012.

- [4] Federal Reserve Bank of St. Louis. Harmonized unemployment rate: All persons for germany. <https://fred.stlouisfed.org/series/LRHUTTTTDEM156S>. Accessed: 2026-05-15.
- [5] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [6] Google. Google trends. <https://trends.google.com/>. Accessed: 2026-05-15.
- [7] Kaggle and Rossmann. Rossmann store sales. <https://www.kaggle.com/c/rossmann-store-sales>, 2015. Accessed: 2026-05-15.
- [8] Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4):1346–1364, 2022.
- [9] Open-Meteo. Historical weather api. <https://open-meteo.com/en/docs/historical-weather-api>. Accessed: 2026-05-15.
- [10] Natalie Rose and Les Dolega. It’s the weather: Quantifying the impact of weather on retail sales. *Applied Spatial Analysis and Policy*, 15(1):189–214, 2022.